

# Sadistik

# Einführung

Teilgebiet	Beschreibung	Techniken
Deskriptive Statistik	Zusammenfassung & Visualisierung von Daten	Grafiken, Tabellen, Kennzahlen
Explorative Statistik	Suche nach Struktur in Daten Schnittstelle zwischen der deskriptiven & induktiven Stat.	Iterative und interaktive Anwendung von Techniken aus der deskriptiven und induktiven Statistik.
Induktive Statistik	Schließt von beobachteten Daten auf allgemeine Phänomene.	Statistische Modellierung, Statistische Tests, Inferenz

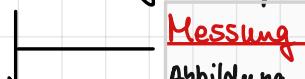
## Datenerhebung & Messung

### Statistische Einheit, Untersuchungseinheit (UE)

Objekte, an denen Größen erfasst werden.

### Merkmal, Variable

Messbare Eigenschaft einer UE.



### Merkmaalsausprägung

Konkreter Wert eines Merkmals für eine bestimmte UE.

### Beobachtung

Die Gesamtheit der beobachteten Merkmalsausprägungen der gemessenen Merkmale einer UE zu einem bestimmten Zeitpunkt.

### Gütekriterien für Messungen

#### Validität

(Häufigkeit) Wird das gemessen, was gemessen werden soll?

$$\hookrightarrow \text{Bias} = 0$$

### Grundgesamtheit, Population (GG)

E Menge aller, für eine Fragestellung relevanten, statistischen Einheiten.

### Teilgesamtheit, Stichprobe

= Teilmenge der GG

Eine gültige Messung ist ein Homomorphismus

↓ bzgl. dieser Relation

Durch die Messbarkeit lässt sich eine Relation zwischen den UE definieren

#### Reliabilität

(Zuverlässigkeit) Ist die Messung zuverlässig?

$$\hookrightarrow r = \frac{\sigma_X^2}{\sigma_{X^*}^2}, \quad X^* = X + U$$

↑ Messfehler  
↑ beobachtete Messwerte

# Skalenniveaus

Skalenniveau	Beispiele	Erlaubte Transformationen um Strukturen zu erhalten	Werte	Ordnung	Differenz	Quotient	Lageparameter
Nominalskala	Wohnort, Farbe	Bijektionen	✓	✗	✗	✗	Mode
Ordinal - Rangskala	Soziale Schicht, Schulbildung	str. monoton steig. Abb.	✓	✓	✗	✗	Median
Intervallskala *	Temperatur, IQ, Jahreszahlen	affin lin. str. mon. steig. Abb.	✓	✓	✓	✗	Arith. Mittel
Verhältnisskala ** <small>(Intervallskala mit natürlicher Null) d.h. minimum des Skala ist Null</small>	Preis, Länge, Gewicht	lineare str. mon. steig. Abb.	✓	✓	✓	✓	Geom. Mittel Harm. Mittel
Absolutskala	Häufigkeit, Anzahl	Identität	✓	✓	✓	✓	!!

\* Äquivalenzrelation

$S := \text{Skalen}, D := S \times S, R = \{(m_1, n) \in D \times D \mid (m_1, m_2) \in D \wedge (n, n_2) \in D \wedge m_1 - m_2 = n_1 - n_2\} \subseteq D \times D$  für Ordnungsrelation

\*\* Äquivalenzrelation

$R = \{(m, n) \in D \times D \mid (m_1, m_2) \in D \wedge (n, n_2) \in D \wedge \frac{m_1}{m_2} = \frac{n_1}{n_2}\} \subseteq D \times D$  für Ordnungsrelation

## Indexbildung

Zusammenfassung von Einzelindikatoren zu einer neuen Variable

## Datenerhebung

### Vollerhebung

Alle stat. Einheiten einer GG werden untersucht.

### Stichprobe

Ein Teil der UE in einer GG wird untersucht.

### Querschnittdaten

Eine Beobachtung pro UE.

### Zeitreihe

Mehrere Beobachtungen einer UE.

### Längsschnittdaten

Mehrere Beobachtungen mehrerer UE.

- Noten, Aktivitäten, Geschlecht, können zu bestimmtem Zeitpunkt von UE erhoben werden und z.B. mittels Regression auf Zusammenhänge untersucht werden.

- Temperatur, Wind & Luftfeuchtigkeit werden in regelmäßigen Abständen gemessen um Prognosen über die zeitliche Entwicklung der UE 'Wetter' zu machen

- Kohortenstudien in Medizin
- Mikrozensus

# Grundräume

## Ergebnisraum

$\Omega \neq \emptyset$  heißt Grundgesamtheit oder Ergebnisraum.  
 $A \subseteq \Omega$  heißt Ereignis.  
 $\omega \in \Omega$  heißt Elementarereignis oder Ergebnis.

## Meßraum / meßbar

Sei  $F$  eine  $\sigma$ -Algebra über  $\Omega$  und  $A \in F$ , dann heißt  $A$  meßbar bezüglich  $F$ . Das Tupel  $(\Omega, F)$  heißt Meßraum (measurable space).

## $\sigma$ -Algebra

Ein Mengensystem  $F \subseteq P(\Omega)$  heißt  $\sigma$ -Algebra über  $\Omega$  oder abgeschlossenes Mengensystem, falls gilt:  
i)  $\Omega \in F$  ii)  $A \in F \Rightarrow \bar{A} \in F$  iii)  $A_i \in F, i \in I \Rightarrow \bigcup_{i \in I} A_i \in F$

## Erzeuger

Sei  $E \subseteq P(\Omega)$  und  $\Sigma$  die Menge aller  $\sigma$ -Algebren über  $\Omega$ , die  $E$  enthalten. Dann wird die  $\sigma$ -Algebra  $\sigma(E) := \bigcap_{F \in \Sigma} F$  als die von  $E$  erzeugte  $\sigma$ -Algebra  $\sigma(E)$  bezeichnet. Gilt umgekehrt für eine  $\sigma$ -Algebra  $\mathcal{A}$ ,  $\sigma(E) = \mathcal{A}$ , so heißt  $E$  Erzeuger von  $\mathcal{A}$ .

## Erzeugende $\sigma$ -Algebra

Ist  $A \subseteq \Omega$ , so heißt die Menge  $\sigma(A) = \{\emptyset, A, \bar{A}, \Omega\}$  die von  $A$  erzeugte  $\sigma$ -Algebra und ist die kleinste  $\sigma$ -Algebra die  $A$  enthält.

## Satz

Sei  $I \neq \emptyset$  eine beliebige Indexmenge und  $F_i$  eine  $\sigma$ -Algebra über  $\Omega$  für  $i \in I$ .  
Dann ist auch  $F := \bigcap_{i \in I} F_i$  eine  $\sigma$ -Algebra über  $\Omega$ .

## Eigenschaften von $B$

- i)  $\emptyset \in B, \Omega \in B$
- ii)  $\forall a, b \in \mathbb{R}, a < b : [a, b] \in B \wedge [a, b) \in B \wedge (a, b] \in B$
- iii)  $\forall a \in \mathbb{R} : \{a\} \in B$
- iv)  $\bigcup_{n \in \mathbb{N}} B_n \in B, \bigcap_{n \in \mathbb{N}} B_n \in B, \overline{B} \in B$

# Wahrscheinlichkeitsmaß

## Mathematisches Maß

### Maß und Meßraum

Sei  $(\Omega, F)$  ein Meßraum. Eine Funktion  $\mu : F \rightarrow \overline{\mathbb{R}}$  heißt Maß auf  $F$ , falls gilt:

$$i) \mu(\emptyset) = 0$$

$$ii) \forall A \in F : \mu(A) \geq 0$$

$$iii) \sigma\text{-Additivität: } \mu\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} \mu(A_i)$$

Wir nennen  $(\Omega, F, \mu)$  Meßraum (measure space).

### Reduziertes Maß

Sei  $\mu$  ein Maß auf  $F$  und  $A \in F$ . Dann heißt  $\mu|_A$  reduziertes Maß und ist definiert durch  $\mu|_A(B) := \mu(A \cap B) \forall B \in F$ .

### Zählmaß

$$\mu_z(A) := \begin{cases} |A|, & A \text{ endlich} \\ +\infty, & \text{sonst} \end{cases}$$

!  $\mu_z$  ist  $\sigma$ -endlich, wenn  $\Omega$  abzählbar ist.

### Maßeindringlichkeitssatz

Seien  $\mu, \nu$  zwei Maße auf  $(\Omega, F)$  und  $E$  ein durchschnittsstabiles Erzeuger von  $F$  mit den Eigenschaften:

$$i) \mu(E) = \nu(E) \quad \forall E \in E$$

ii) Es gibt eine Folge  $(E_n)_{n \in \mathbb{N}}$  disjunkter Mengen aus  $E$  mit  $\mu(E_n) = \nu(E_n) < \infty$  und  $\bigcup_{n=1}^{\infty} E_n = \Omega$ .

Dann sind die beiden Maße identisch:  $\mu = \nu$ .

### Indikatorkfunktion

Sei  $A \subseteq \Omega$ .  $I_A : \Omega \rightarrow \mathbb{R}$ ,  $I_A(\omega) := \begin{cases} 1, & \omega \in A \\ 0, & \omega \notin A \end{cases}$

## Satz

Seien  $A, B \subseteq \Omega$ . Dann gilt

$$i) I_{\bar{A}} = 1 - I_A \quad ii) I_{A \cap B} = I_A \cdot I_B$$

$$iii) A \cap B = \emptyset \Rightarrow I_{A \cup B} = I_A + I_B \quad iv) A \subseteq B \Rightarrow I_{B|A} = I_B - I_A$$

### Terminologie

Gibt es eine Folge  $(A_i)_{i \in \mathbb{N}}$  in  $F$ , s.d.  $\bigcup_{i=1}^{\infty} A_i = \Omega$  und  $\mu(A_i) < \infty \quad \forall i \in \mathbb{N}$ , so heißt  $\mu$   $\sigma$ -endlich.

Ist außerdem  $\mu(\Omega) < \infty$ , so heißt  $\mu$  endlich.

Ist außerdem  $\mu(\Omega) = \infty$ , so heißt  $\mu$  normiert.

### Durchschnittsstabil / $\pi$ -System

Ein Mengensystem  $F \subseteq P(\Omega)$  heißt durchschnittsstabil, oder  $\pi$ -System, wenn gilt:

$$A, B \in F \Rightarrow A \cap B \in F$$

!  $\emptyset$  ist durchschnittsstabil

### Lebesgue-Maß

Für  $B \in \mathbb{R}^n$  mit  $B = \bigcup_{i=1}^n (a_i, b_i)$  definieren wir

$$\text{vol}(B) := (b_1 - a_1) \cdots (b_n - a_n)$$

Für  $A \subseteq \mathbb{R}^n$  definieren wir

$$\lambda^*(A) = \inf \left\{ \sum_{B \in \mathcal{C}} \text{vol}(B) \mid A \subseteq \bigcup_{i=1}^n B, \mathcal{C} \right\}$$

Das Lebesgue-Maß ist definiert als  $\lambda(A) = \lambda^*(A)$  für alle Lebesgue-messbaren Mengen  $A$ , d.h. für alle  $A \subseteq \mathbb{R}^n$  für die

gilt  $\forall S \subseteq \mathbb{R}^n : \lambda^*(S) = \lambda^*(S \cap A) + \lambda^*(S \setminus A)$

### Dirac Maß / Dirac Verteilung

Sei  $s_w : F \rightarrow \mathbb{R}$ ,  $s_w(A) := I_A(w) = \begin{cases} 1, & w \in A \\ 0, & w \notin A \end{cases}$ .  
 $s_w$  heißt Dirac Maß.

Für  $w \in \Omega$  heißt  $P(w) = s_w$  Dirac Verteilung oder Einpunktverteilung.

Es gilt also  $P(w) = 1 \wedge P(w') = 0 \quad \forall w' \in \Omega, w' \neq w$ .

# Wahrscheinlichkeitsmaß

## Wahrscheinlichkeitsmaß / Verteilung

Sei  $(\Omega, \mathcal{F})$  ein Maßraum und  $\text{IP}: \mathcal{F} \rightarrow [0, 1]$  ein Maß auf  $(\Omega, \mathcal{F})$  mit  $\text{IP}(\Omega) = 1$ . Dann heißt  $\text{IP}$  Wahrscheinlichkeitsmaß oder Verteilung und ordnet jedem Ereignis  $A \in \mathcal{F}$  die Wahrscheinlichkeit  $\text{IP}(A)$  zu.  $(\Omega, \mathcal{F}, \text{IP})$  heißt Wahrscheinlichkeitsraum.

## Laplace-Wahrscheinlichkeit

Sei  $(\Omega, \mathcal{F})$  ein Maßraum,  $|\Omega| < \infty$  und  $\text{IP}: \mathcal{F} \rightarrow [0, 1]$  ein Maß auf  $(\Omega, \mathcal{F})$  mit  $\text{IP}[A] := \frac{|A|}{|\Omega|}$ . Wir nennen  $\text{IP}$  die Laplace-Wahrscheinlichkeit.

## Eigenschaften

### Eigenschaften eines Maßes

Sei  $(\Omega, \mathcal{F}, \mu)$  ein Maßraum und  $A, B, A_n \in \mathcal{F}, \forall n \in \mathbb{N}$ . Dann gilt:

- i) Endliche Additivität:  $A \cap B = \emptyset \Rightarrow \mu(A \cup B) = \mu(A) + \mu(B)$ .
- ii) Subadditivität:  $A \subseteq B \wedge \mu(A) < \infty \Rightarrow \mu(B|A) = \mu(B) - \mu(A)$
- iii) Monotonie:  $A \subseteq B \Rightarrow \mu(A) \leq \mu(B)$
- iv) Sub- $\sigma$ -Additivität:  $\mu(\bigcup_{n=1}^{\infty} A_n) \leq \sum_{n=1}^{\infty} \mu(A_n)$ .

### Satz

- $\bullet P[\bigcap_{i=1}^n A_i] = \prod_{i=1}^n P[A_i | \bigcap_{j=1}^{i-1} A_j] = P[A_1] \cdot P[A_2 | A_1] \cdot P[A_3 | A_1 \cap A_2] \dots P[A_n | A_1 \cap \dots \cap A_{n-1}]$  (Multiplikationssatz)
  - $\bullet$  Sei  $(A_i)_{i \in I}$  eine disjunkte Zerlegung von  $\Omega$ . d.h.  $\Omega = \bigcup_{i \in I} A_i$ . dann gilt für beliebiges  $B$ :  $P[B] = \sum_{i \in I, P(A_i) > 0} P[B|A_i] \cdot P[A_i]$  (Satz von totaler Wahrscheinlichkeit)
- Spezialfall:  $P(B) = P(B|A) \cdot P(A) + P(B|A^c) \cdot P(A^c)$

### Satz von Bayes

$(A_i)_{i \in I}$  sei so, dass  $\Omega = \bigcup_{i \in I} A_i$ .  $B$  sei so, dass  $P[B] \neq 0$ .

Dann ist  $P[A_i | B] = \frac{P[B | A_i] \cdot P[A_i]}{\sum_j P[B | A_j] \cdot P[A_j]}$  Spezialfall:  $P(A | B) = \frac{P(B | A) \cdot P(A)}{P(B)}$   $= \frac{P(B | A) \cdot P(A)}{P(B | A) \cdot P(A) + P(B | A^c) \cdot P(A^c)}$

### Wettverhältnis (Odds-Update)

Faktor der neuen Information  

$$\frac{P[B | A]}{P[B^c | A]} = \frac{\overbrace{P[A | B]}^{\text{a posteriori Verhältnis}} \cdot P[B]}{\overbrace{P[A | B^c]}^{\text{a priori Verhältnis}} \cdot P[B^c]}$$

Sensitivität:  $P(T^+ | K^+)$   
 Spezifität:  $P(T^- | K^-)$   
 Prävalenz:  $P(K)$   
 Relevant:  $P(K | T^+)$   
 Irrelevant:  $P(K | T^-)$

## $\mu$ -fast-überall / IP-fast-sicher

Ist  $(\Omega, \mathcal{F}, \mu)$  ein Maßraum und  $A \in \mathcal{F}$  mit  $\mu(A) = 0$ , so heißt  $A$   $\mu$ -Nullmenge.

Eine Eigenschaft  $E$  gilt  $\mu$ -fast-überall in  $\Omega$ , wenn:

$\exists N \in \mathbb{N}: \mu(N) = 0 \wedge \forall \omega \in \Omega \setminus N: E$  gilt für  $\omega$ .

Wir sagen  $E$  gilt IP-fast-sicher, wenn es für ein Wahrscheinlichkeitsmaß  $\text{IP}$   $E$  IP-fast-überall gilt.

## Bedingte Wahrscheinlichkeit

Ist  $(\Omega, \mathcal{F}, \text{IP})$  ein Wahrscheinlichkeitsraum und  $\text{IP}(B) > 0$  für  $B \in \mathcal{F}$ , so heißt  $\text{IP}(\cdot | B): \mathcal{F} \rightarrow [0, 1], A \mapsto \text{IP}(A | B) = \frac{\text{IP}(A \cap B)}{\text{IP}(B)}$  die bedingte Wahrscheinlichkeitsverteilung bzw. bedingte Wahrscheinlichkeit von  $A$  gegeben  $B$ .

### Satz

$\text{IP}(\cdot | B)$  ist ein Wahrscheinlichkeitsmaß auf  $(\Omega, \mathcal{F})$ .

### Stetigkeit des Maßes

Sei  $(\Omega, \mathcal{F}, \mu)$  ein Maßraum und  $A, A_n \in \mathcal{F}, n \in \mathbb{N}$ .

Dann gilt:

- i) Stetigkeit von unten: Sei  $A_1 \subseteq A_2 \subseteq \dots \Rightarrow \mu(\bigcup_{k=1}^{\infty} A_k) = \lim_{k \rightarrow \infty} \mu(A_k)$
- ii) Stetigkeit von oben: Sei  $A_1 \supseteq A_2 \supseteq \dots$  und  $\mu(A_n) < \infty \Rightarrow \mu(\bigcap_{k=1}^{\infty} A_k) = \lim_{k \rightarrow \infty} \mu(A_k)$

### Stetigkeit des Wahrscheinlichkeitsmaßes

Sei  $(\Omega, \mathcal{F}, \text{IP})$  ein W-Maßraum und  $A, A_1, A_2, \dots \in \mathcal{F}$

Dann gilt:

- i) Sei  $A_1 \subseteq A_2 \subseteq \dots \Rightarrow \text{IP}(\bigcup_{k=1}^{\infty} A_k) = \lim_{k \rightarrow \infty} \text{IP}(A_k)$
- ii) Sei  $A_1 \supseteq A_2 \supseteq \dots \Rightarrow \text{IP}(\bigcap_{k=1}^{\infty} A_k) = \lim_{k \rightarrow \infty} \text{IP}(A_k)$

### Siebformel von Sylvester-Poincaré

Sei  $(\Omega, \mathcal{F}, \text{IP})$  ein W-Maßraum und  $A_1, A_2, \dots \in \mathcal{F}$ , dann gilt die Verallgemeinerung von (ii) von oben:

$$\begin{aligned} \text{P}[\bigcup_{i=1}^n A_i] &= \sum_{k=1}^n (-1)^{k+1} \cdot \sum_{1 \leq i_1 < \dots < i_k \leq n} \text{P}[A_{i_1} \cap \dots \cap A_{i_k}] \\ &= \sum_{i=1}^n \text{P}[A_i] - \sum_{1 \leq i < j \leq n} \text{P}[A_i \cap A_j] \\ &\quad + \sum_{1 \leq i < j < k \leq n} \text{P}[A_i \cap A_j \cap A_k] - \dots + (-1)^{n+1} \text{P}[\bigcap_{i=1}^n A_i] \end{aligned}$$

Spezialfall:  $\text{P}(A \cup B) = \text{P}(A) + \text{P}(B) - \text{P}(A \cap B)$

# Zufallsvariablen (Theorie)

## Urbild

Seien  $X, Y$  nicht-leere Mengen. Für eine Abbildung  $f: X \rightarrow Y$  und  $A \in \mathcal{P}(Y)$  definieren wir  $f^{-1}(A) = \{x \in X \mid f(x) \in A\} = \{f \in A\}$ .  $f^{-1}$  heißt Urbild von  $A$ .

## Eigenschaften:

$$i) f^{-1}(A^c) = (f^{-1}(A))^c \quad \forall A \in \mathcal{P}(Y).$$

$$ii) f^{-1}(A \cap B) = f^{-1}(A) \cap f^{-1}(B) \quad \forall A, B \in \mathcal{P}(Y)$$

$$iii) f^{-1}\left(\bigcup_{k=1}^{\infty} A_k\right) = \bigcup_{k=1}^{\infty} f^{-1}(A_k) \quad \forall \{A_k\}_{k \in \mathbb{N}} \subseteq \mathcal{P}(Y). \quad f^{-1}(\mathcal{F}_1) := \{f^{-1}(A) \mid A \in \mathcal{F}_1\} \text{ ist eine } \sigma\text{-Algebra.}$$

## Satz

Sei  $(Y, \mathcal{F})$  ein Maßraum, dann ist  $(X, f^{-1}(\mathcal{F}))$  ein Maßraum. D.h.

## Messbare Abbildung

Seien  $(\Omega_1, \mathcal{F}_1), (\Omega_2, \mathcal{F}_2)$  Maßräume. Eine Abbildung  $f: \Omega_1 \rightarrow \Omega_2$  heißt  $\mathcal{F}_1$ - $\mathcal{F}_2$ -messbar, wenn  $f^{-1}(\mathcal{F}_2) \subseteq \mathcal{F}_1$ .

Man spricht abgekürzt von einer messbaren Abbildung  $f$ , falls die involvierten  $\sigma$ -Algebren eindeutig bekannt sind.

↓

## Bildmaß

Ist  $(\Omega_1, \mathcal{F}_1, \mu)$  ein Maßraum und  $(\Omega_2, \mathcal{F}_2)$  ein Maßraum und  $f: \Omega_1 \rightarrow \Omega_2$  messbar, so heißt  $\mu_f: \mathcal{F}_2 \rightarrow [0, \infty]$ ,  $\mu_f(A) := \mu(f^{-1}(A))$  das Bildmaß  $\mu_f$  von  $\mu$  unter  $f$ .  $(\Omega_2, \mathcal{F}_2, \mu_f)$  ist ein Maßraum.

## Zufallsvariablen

## Zufallsvariable

Ist  $(\Omega_1, \mathcal{F}_1, \mathbb{P})$  ein Wahrscheinlichkeitsraum und  $(\Omega_2, \mathcal{F}_2)$  ein Maßraum, so heißt eine  $\mathcal{F}_1$ - $\mathcal{F}_2$ -messbare Abb.  $X: \Omega_1 \rightarrow \Omega_2$  Zufallsvariable (ZV).

↓

## Verteilung einer Zufallsvariable

Ist  $(\Omega_1, \mathcal{F}_1, \mathbb{P})$  ein Wahrscheinlichkeitsraum und  $(\Omega_2, \mathcal{F}_2)$  ein Maßraum und  $X: \Omega_1 \rightarrow \Omega_2$  eine ZV, so heißt das Bildmaß  $\mathbb{P}_X$  von  $\mathbb{P}$  unter  $X$  die Verteilung von  $X$ .

Das Bildmaß  $\mathbb{P}_X$  von  $\mathbb{P}$  unter  $X$ ,  $\mathbb{P}_X(A) := \mathbb{P}(X^{-1}(A)) \in [0, 1] \quad \forall A \in \mathcal{F}_2$ ,

ist wieder ein Wahrscheinlichkeitsmaß.

! Unterschied zu Dichte  $f$  in Statistik!

$f: \Omega \rightarrow \mathbb{R}, \quad f(x) := \mathbb{P}(X^{-1}(\{x\}))$  funktioniert nicht für stetige ZV.

$\mathbb{P}_X: \mathcal{F} \rightarrow \mathbb{R}, \quad \mathbb{P}_X(\{x\}) := \mathbb{P}(X^{-1}(\{x\}))$

## Beispiel

Sei  $\Omega = \{0, 1\}^n, \mathcal{F} = \mathcal{P}(\Omega)$ .  $\mathbb{P}(\{\omega\}) = p^k(1-p)^{n-k}$ , wobei  $k$  die Anzahl der 1er und  $p$  die Wahrscheinlichkeit für eine 1 beschreibt.

Sei  $X: \Omega \rightarrow \mathbb{N}_0$  die messbare Abb. die jedem  $\omega \in \Omega$  die Anzahl der 1er zuordnet.

$$\text{Dann ist } \mathbb{P}_X(\{k\}) = \mathbb{P}(X^{-1}(\{k\})) = \sum_{\omega \in X^{-1}(\{k\})} \mathbb{P}(\{\omega\}) = \binom{n}{k} p^k (1-p)^{n-k}$$

## Satz

Seien  $(\Omega_1, \mathcal{F}_1), (\Omega_2, \mathcal{F}_2)$  Maßräume, wobei  $\mathcal{F}_2 = \sigma(E)$  von einem Mengensystem  $E$  erzeugt ist. Die Abb.  $f: \Omega_1 \rightarrow \Omega_2$  ist genau dann  $\mathcal{F}_1$ - $\mathcal{F}_2$ -messbar, wenn  $f^{-1}(E) \subseteq \mathcal{F}_1$ .

## Beispiel

Für Maßräume  $(\Omega, \mathcal{F})$  und  $(\mathbb{R}, \mathcal{B})$  heißt die Abb.  $f: \Omega \rightarrow \mathbb{R}$   $\mathcal{F}$ - $\mathcal{B}$ -messbar, wenn  $f^{-1}(\{-\infty\}), f^{-1}(\{\infty\}) \in \mathcal{F}$  und  $f^{-1}((-\infty, a)) \in \mathcal{F} \quad \forall a \in \mathbb{R}$ .

## Satz

Sind  $(\Omega_i, \mathcal{F}_i), i=1,2,3$  Maßräume und  $f: \Omega_1 \rightarrow \Omega_2$  und  $g: \Omega_2 \rightarrow \Omega_3$  messbar. Dann ist auch  $f \circ g: \Omega_1 \rightarrow \Omega_3$  messbar.

## Satz

Sei  $X: \Omega \rightarrow \mathbb{R}^n$  eine ZV und  $g: \mathbb{R}^n \rightarrow \mathbb{R}^m$  messbar. Dann ist  $g \circ X: \Omega \rightarrow \mathbb{R}^m$  eine ZV.

## Satz

Es sei  $(\Omega, \mathcal{F})$  ein Maßraum.  $f, g: \Omega \rightarrow \mathbb{R}$  messbare Funktionen und  $\alpha, \beta \in \mathbb{R}$ . Dann sind die Funktionen a)  $\alpha f + \beta \cdot g$  b)  $f \cdot g$  c)  $f/g$ , falls  $g(\omega) \neq 0 \quad \forall \omega \in \Omega$  ebenfalls messbar.

## Unabhängigkeit

## Unabhängigkeit von Ereignissen

Sei  $(\Omega, \mathcal{F}, \mathbb{P})$  ein Wahrscheinlichkeitsraum. Ereignisse  $A_i \in \mathcal{F}, i \in I \neq \emptyset$  heißen paarweise stochastisch unabhängig, wenn  $\forall J \subseteq I$  nicht-leer gilt:

$$\mathbb{P}\left(\bigcap_{j \in J} A_j\right) = \prod_{j \in J} \mathbb{P}(A_j)$$

## Stochastisch unabhängige Mengensysteme

Eine Familie von Mengensystemen  $\mathcal{F}_i \subseteq \mathcal{P}(\Omega_i)$ ,  $i \in I \neq \emptyset$ , heißt stochastisch unabhängig, wenn dies für jede Familie von Ereignissen  $A_j \in \mathcal{F}_i$ ,  $j \in J$ , für alle  $i \in I$  gilt.

## Stochastisch unabhängige Zufallsvariablen

Eine Familie von ZV's  $X_i: \Omega_i \rightarrow \Omega_i$  auf einem W-raum  $(\Omega, \mathcal{F}, \mathbb{P})$  heißt stochastisch unabhängig, wenn dies für die Familie der von den ZV's  $X_i$  erzeugten  $\sigma$ -Algebren  $\mathcal{F}(X_i) = \sigma(X_i^{-1}(\mathcal{F}_i))$   $i \in I$  gilt.

## Satz

Seien  $X_1, \dots, X_n$  reelle ZV's.  $X_1, \dots, X_n$  sind stochastisch unabhängig, genau dann wenn  $\forall c \in \mathbb{R}^n$ .  $\mathbb{P}(X_1 \leq c_1, \dots, X_n \leq c_n) = \prod_{i=1}^n \mathbb{P}(X_i \leq c_i)$

# Zufallsvariablen (Emperie)

## Notation & Terminologie

Bezeichnung in der Emperie	Bezeichnung in der Theorie
Merkmal	Zufallsvariable $X, Y, \dots$
Anzahl Untersuchungseinheiten	$n$
Merkmalsausprägung von Merkmal $X$ der $i$ -ten UE.	$x_i, i \in \{1, \dots, n\}$
Rohdaten / Urliste	$x_1, \dots, x_n$
(evtl. geordnete) verschiedene Werte aus der Urliste	$a_1, \dots, a_k, k \leq n, a_i \in \{x_1, \dots, x_n\}$ (Eindeutige Elemente der Urliste)
relative Häufigkeit $f_j$	Wahrscheinl. bzw. Dichte $f_x(a_j)$
kum. rel. Häufigkeit $F(x)$	Verteilungsfunktion $F_x(x)$

### Absolute Häufigkeit

Die absolute Häufigkeit von  $a_j$  ist die Anzahl der  $x_i$  aus der Urliste mit  $x_i = a_j$   
 $h(a_j) = h_j$

### Relative Häufigkeit

Die relative Häufigkeit von  $a_j$  ist der Anteil des  $x_i$  an der Urliste für die gilt  $x_i = a_j$ .  $f(a_j) = f_j = \frac{h_j}{n}$

### Absolute / relative Häufigkeitsverteilung

$h_1, \dots, h_k$  heißt absolute Häufigkeitsverteilung  
 $f_1, \dots, f_k$  heißt relative Häufigkeitsverteilung

### Kumulative relative Häufigkeit / empirische Verteilungsfunktion

(Sinnvoll bei ordinal oder metrisch)

$$F(x) = (\text{Anteil UE mit } x_i \leq x) = \sum_{a_i \leq x} f(a_i) \quad (\text{ECDF})$$

- monoton wachsende Treppenfkt. mit Sprüngen bei  $a_1, \dots, a_k$ .
- Sprunghöhe  $f_1, \dots, f_k$
- rechtsseitig stetig
- $F(x) = 0$  für  $x < a_1$ ,  $F(x) = 1$  für  $x \geq a_k$

## Zusammenhangsmaße für diskrete ZV

### Kontingenztafel der absoluten Häufigkeiten

Seien  $X, Y$  diskrete Merkmale mit Ausprägungen  $a_1, \dots, a_k$  für  $X$  und  $b_1, \dots, b_m$  für  $Y$ . Eine  $(k \times m)$ -Kontingenztafel der absoluten Häufigkeiten besitzt die Form:

$h_{ij} = h(a_i, b_j) = \text{Absolute Häufigkeit der Kombination } (a_i, b_j)$

$h_{i \cdot} = \text{Randhäufigkeit von } a_i \text{ in } X, h_{\cdot j} = \text{Randhäufigkeit von } b_j \text{ in } Y$

$b_1 \dots b_m$	$h_{11} \dots h_{1m}$	$h_{1 \cdot}$
$a_2$	$h_{21} \dots h_{2m}$	$h_{2 \cdot}$
$\vdots$	$\vdots$	$\vdots$
$a_k$	$h_{k1} \dots h_{km}$	$h_{k \cdot}$
	$h_{\cdot 1} \dots h_{\cdot m}$	$n$

### Kontingenztafel der relativen Häufigkeiten

Seien  $X, Y$  diskrete Merkmale mit Ausprägungen  $a_1, \dots, a_k$  für  $X$  und  $b_1, \dots, b_m$  für  $Y$ .

Eine  $(k \times m)$ -Kontingenztafel der relativen Häufigkeiten besitzt die Form:

$f_{ij} = \frac{h_{ij}}{n} = \text{Relative Häufigkeit der Kombination } (a_i, b_j)$

$f_{i \cdot} = \frac{h_{i \cdot}}{n} = \text{relative Randhäufigkeit von } a_i \text{ in } X;$

$f_{\cdot j} = \frac{h_{\cdot j}}{n} = \text{relative Randhäufigkeit von } b_j \text{ in } Y$

$b_1 \dots b_m$	$f_{11} \dots f_{1m}$	$f_{1 \cdot}$
$\vdots$	$\vdots$	$\vdots$
$a_k$	$f_{k1} \dots f_{km}$	$f_{k \cdot}$
	$f_{\cdot 1} \dots f_{\cdot m}$	$1$

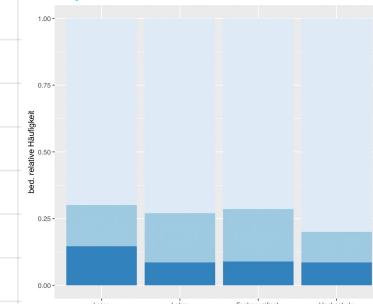
### Bedingte Häufigkeitsverteilung

Die bedingte Häufigkeitsverteilung von  $Y$  unter der Bedingung  $X=a_i$ ;  $(Y|X=a_i)$  ist definiert als  $f_y(b_1|a_i) = \frac{h_{1i}}{h_{i \cdot}}, \dots, f_y(b_m|a_i) = \frac{h_{mi}}{h_{i \cdot}}$

### Satz

Wegen  $\frac{h_{ij}}{h_{i \cdot}} = \frac{h_{ij}/n}{h_{i \cdot}/n} = \frac{f_{ij}}{f_{i \cdot}}$  gilt,  
 $f_y(b_j|a_i) = \frac{f_{ij}}{f_{i \cdot}} \quad \forall i, j$

### Beispiel



### Bedingte Odds & Odds ratio

Für festes  $X=a_i$  bezeichnen wir  $g(1,2|X=a_i) = \frac{h_{1i}}{h_{2i}}$  als bedingte Odds.

Als relative Chancen (Odds ratio) bezeichnen wir  $g(1,2|X=1, X=2) = \frac{g(1,2|X=1)}{g(1,2|X=2)} = \frac{h_{11} \cdot h_{22}}{h_{21} \cdot h_{12}}$

### Erwartete absolute/relative Häufigkeit

Unter empirischer Unabhängigkeit wird erwartet, dass  $f_Y(b_j | a_i) = f_Y(b_j)$   $\forall i, j$  gilt.  
Daher gilt für die erwartete absolute Häufigkeit  $\tilde{h}_{ij}$ :  $\tilde{h}_{ij} = \frac{h_{i \cdot} \cdot h_{\cdot j}}{n}$  (nicht immer  $\in \mathbb{N}$ )  
Und für die erwartete relative Häufigkeit  $\tilde{f}_{ij}$ :  $\tilde{f}_{ij} = f_{i \cdot} \cdot f_{\cdot j}$ .

Odds ratio (Kreuzproduktverhältnis) ist symmetrisch bezüglich der Wahl von  $X, Y$ .

$j(Y=1, Y=2 | X=1, X=2) = j(X=1, X=2 | Y=1, Y=2)$   $\heartsuit$  Symmetrisches Maß und kann als Risikofaktor interpretiert werden:

- $j=1$ : Odds in beiden Populationen gleich.
- $j > 1$ : Odds in  $X=1$  höher als in  $X=2$
- $j < 1$ : Odds in  $X=1$  niedriger als in  $X=2$ .

### $\chi^2$ -Koeffizient

Zusammenhangsmaß zum Quantifizieren vom "Abstand" zwischen beobachteten und erwarteten gemeinsamen Häufigkeiten.

$$\chi^2 = \sum_{i=1}^k \sum_{j=1}^m \frac{(h_{ij} - \tilde{h}_{ij})^2}{\tilde{h}_{ij}}$$

$$\chi^2 \in [0, n \cdot \min(k, m) - 1]$$

$\chi^2 = 0 \Leftrightarrow X, Y$  empirisch unabhängig

$\chi^2$  gross  $\Leftrightarrow$  starker Zusammenhang

?  $\chi^2$  hängt von  $n, k$  und  $m$  ab  
 $\hookrightarrow$  schwer zu interpretieren.

### Satz

Für eine Kontingenztafel der Form

a	b
c	d

$$\chi^2 = \frac{n \cdot (a \cdot d - c \cdot b)^2}{(a+b)(a+c)(c+d)(b+d)}$$

### (Korrigierter) Kontingenzkoeffizient

! Misst nur Stärke des Zusammenhangs,

Nicht die Richtung, wie bei  $j$

Normierung von  $\chi^2$ : Kontingenzkoeffizient  $K := \sqrt{\frac{\chi^2}{n + \chi^2}}$ ,  $K \in [0, \sqrt{\frac{\min\{k, m\}-1}{\min\{k, m\}}}]$

Korrigierter Kontingenzkoeffizient  $K^* := \frac{K}{\sqrt{\frac{\min\{k, m\}-1}{\min\{k, m\}}}}$ ,  $K^* \in [0, 1]$

# Verteilungsfunktion

## Verteilungsfunktion

Ist  $\text{IP}: \mathbb{B} \rightarrow [0,1]$  ein  $\omega$ -maß auf  $\mathbb{R}$ , so heißt  
 $F_{\text{IP}}: \mathbb{R} \rightarrow [0,1], x \mapsto F_{\text{IP}}(x) := \text{IP}([-\infty, x])$   
die Verteilungsfunktion von  $\text{IP}$ .

### Beispiel Binomialverteilung

$$\text{IP}(\{k\}) = \binom{n}{k} \cdot p^k \cdot (1-p)^{n-k} \cdot I_{\{0, \dots, n\}}(k)$$

Dann:  $F_{\text{IP}}(x) = \text{IP}([-\infty, x]) = \text{IP}\left(\bigcup_{k=0}^{\lfloor x \rfloor} \{k\}\right) = \sum_{k=0}^{\lfloor x \rfloor} \text{IP}(\{k\})$

### Eigenschaften von Verteilungsfunktionen

Eine Verteilungsfunktion  $F_{\text{IP}}$  ist:

- i) monoton wachsend
- ii) rechtsstetig
- iii) und es gilt  $\lim_{x \rightarrow -\infty} F(x) = 0$  und  $\lim_{x \rightarrow +\infty} F(x) = 1$

### Transformation der Verteilungsfunktion

Für umkehrbare, streng monoton steigende

Transformationen  $g$  gilt:  $F_g(x) = F_X(g^{-1}(x))$

## Alternative Definition

Jede monoton wachsende, rechtsstetige Funktion  $F: \mathbb{R} \rightarrow [0,1]$  mit  $\lim_{x \rightarrow -\infty} F(x) = 0$  und  $\lim_{x \rightarrow +\infty} F(x) = 1$  heißt Verteilungsfunktion.

### Korrespondenzsatz

#### Lebesgue-Stieltjes-Maß von $F$

Für jede Verteilungsfkt.  $F$  ist  $\lambda_F((a,b)) = F(b) - F(a)$  ein  $\omega$ -maß mit  $F_{\lambda_F} = F$ . Umgekehrt gibt es für jeden reellen  $\omega$ -maß  $\text{IP}$  eine Verteilungsfkt.  $F$ .

### Median

Gegeben sei eine eindimensionale ZV mit  $X$  mit Verteilung  $\text{IP}_X$ .  $m \in \mathbb{R}$  heißt Median von  $\text{IP}_X$  bzw.  $X$ , wenn  $\text{IP}_X([-\infty, m]) \geq 0.5$  und  $\text{IP}_X([m, +\infty]) \geq 0.5$

### Quantile

Gegeben sei eine eindimensionale ZV mit  $X$  mit Verteilung  $\text{IP}_X$ .  $q \in \mathbb{R}$  heißt  $p$ -Quantil von  $\text{IP}_X$  bzw.  $X$ , wenn  $\text{IP}_X([-\infty, q]) \geq p$  und  $\text{IP}_X([q, +\infty]) \geq 1-p$

# Lebesgue Integral

## Einfache Funktionen

Sei  $f: \Omega \rightarrow \mathbb{R}$  eine Funktion mit  $|f(\omega)| < \infty$  (also mit nur endlich vielen Funktionswerten). Dann heißt  $f$  einfache Funktion und lässt sich schreiben als  $f = \sum_{i=1}^n y_i \cdot \mathbb{1}_{A_i}$ , wobei  $y_i$  ein Funktionswert ist und  $A_i$  die Menge für die  $f(A_i) = y_i$  gilt.

### $f^+, f^-$

$$f^+ := \max\{0, f\}, f^- := -\min\{0, f\}, f = f^+ + f^-, |f| = f^+ + f^-$$

## Lebesgue-Integral für einfache Funktionen

Sei  $(\Omega, \mathcal{F}, \mu)$  ein Maßraum und  $f$  eine nicht-negative, einfache und  $\mathcal{F}$ -B-messbare Funktion.

Dann definieren wir das Lebesgue-Integral von  $f$  als  $\int f \, d\mu = \int \sum_{i=1}^n y_i \cdot \mathbb{1}_{A_i} \, d\mu = \sum_{i=1}^n y_i \cdot \mu(A_i)$  (geht auch für  $n=\infty$ ).

Sei  $g$  eine einfache,  $\mathcal{F}$ -B-messbare Funktion und  $\int g^+ \, d\mu < \infty$  oder  $\int g^- \, d\mu < \infty$ , dann heißt  $g$   $\mu$ -quasi-integrierbar und wir definieren  $\int g \, d\mu := \int g^+ \, d\mu - \int g^- \, d\mu$

Wenn  $\int g^+ \, d\mu < \infty$  und  $\int g^- \, d\mu < \infty$ , so heißt  $g$   $\mu$ -integrierbar. Auf  $\mathbb{R}^n$  wählt man i.a.R.  $\mu = \lambda$

## Lebesgue-Integral

Sei  $f: \Omega \rightarrow \mathbb{R}$  eine  $\mathcal{F}$ -D-messbare Funktion. Wir definieren das Ober-Integral als

$$\int f \, d\mu := \inf \left\{ \int g \, d\mu \mid g \text{ ist eine } \mu\text{-integrierbare, einfache Funktion mit } g \geq f \text{ } \mu\text{-fast-überall} \right\}$$

Wir nennen  $f$   $\mu$ -integrierbar, wenn  $\int f \, d\mu$  existiert und definieren  $\int f \, d\mu := \int f^+ \, d\mu - \int f^- \, d\mu$

Idee: Annäherung an  $f$  mittels einfachen, messbaren,  $\mu$ -integrierbaren Funktionen.

## Satz

Sei  $(\Omega, \mathcal{F}, \mu)$  ein Maßraum und  $f: \Omega \rightarrow [0, +\infty]$  messbar, dann ist  $f$   $\mu$ -integrierbar. Außerdem gilt dann

$$\int f \, d\mu = 0 \Leftrightarrow f = 0 \text{ } \mu\text{-fast-überall}$$

## Satz

Sei  $X: \Omega \rightarrow \mathbb{R}^n$  eine  $n$ -dim. reelle ZV und  $f: \mathbb{R}^n \rightarrow \mathbb{R}$  eine messbare Fkt., s.d.  $f \circ X: \Omega \rightarrow \mathbb{R}$  int.ber. ist. Dann gilt

$$\int f \, d\mu_X = \int f \circ X \, d\mu$$

## Monotonie und Linearität

Seien  $f_1, f_2: \Omega \rightarrow \mathbb{R}$   $\mu$ -int.ber. Fkt. und  $\alpha, \beta \in \mathbb{R}$ , dann gilt

$$i) f_1 \geq f_2 \text{ } \mu\text{-fast-überall} \Rightarrow \int f_1 \, d\mu \geq \int f_2 \, d\mu$$

$$ii) \alpha f_1 + \beta f_2 \text{ ist } \mu\text{-int.ber und } \int (\alpha f_1 + \beta f_2) \, d\mu = \alpha \int f_1 \, d\mu + \beta \int f_2 \, d\mu$$

## Weitere Eigenschaften

Sei  $f: \Omega \rightarrow \mathbb{R}$  eine  $\mu$ -int.ber Fkt. mit  $\Omega = A_1 \cup A_2$  und  $A_1, A_2 \in \mathcal{F}$ . Dann gilt

$$i) \int f \, d\mu = \int_{A_1} f \, d\mu + \int_{A_2} f \, d\mu$$

$$ii) f|_{A_1} \text{ und } f|_{A_2} \text{ sind } \mu\text{-int.ber mit } \int f|_{A_1} \, d\mu = \int f \, d\mu_{A_1}$$

!

## Korollar

Sei  $f: \Omega \rightarrow \mathbb{R}$  eine  $\mu$ -int.ber Fkt. und  $A_n \in \mathcal{F}$  s.d.  $\mu(A_n) = 0$ . Dann gilt

$$i) \left| \int f \, d\mu \right| \leq \int |f| \, d\mu \quad (\text{Dreiecksungleichung})$$

$$ii) \int f \, d\mu = 0 \quad (\text{Lebesgue-integral von Nullmengen ist Null})$$

## Lebesgue-Integral bzgl. Dirac-Maß

Sei  $w \in \Omega$  und  $\delta_w$  das Dirac-Maß. Sei  $f$  eine messbare Fkt. Dann ist  $f$   $\delta_w$ -int.ber, g.d.w.  $f(w) < \infty$  und es gilt  $\int f \, d\delta_w = f(w)$

## Lebesgue-Integral bzgl. Zählmaß

Für den Maßraum  $(\mathbb{N}, \mathcal{P}(\mathbb{N}), \mu_{\mathbb{N}})$  ist eine Fkt.  $f: \mathbb{N} \rightarrow \mathbb{R}$   $\mu$ -int.ber, g.d.w. die Reihe  $\sum_{n=1}^{\infty} f(n)$  absolut konvergiert. Es gilt  $\int f \, d\mu_{\mathbb{N}} = \sum_{n=1}^{\infty} f(n)$   
→ Integration mit Zählmaß ist gleich Summe der y-Werte

## Riemann- und Lebesgue-Integral

Sei  $f: [a, b] \rightarrow \mathbb{R}$  eine beschränkte, messbare und Riemann-integrierbare Fkt., dann ist  $f$   $\lambda$ -int.ber und  $\int_a^b f(x) \, dx = \int_a^b f \, d\lambda$

## Konvergenzsätze für Lebesgue-Integrale

### Monotone Konvergenz / Satz von Beppo Levi

Sei  $\{f_n\}_{n \in \mathbb{N}}$  eine Folge von messbaren, numerischen Funktionen, s.d.  $\forall n \in \mathbb{N}: f_n \leq f_{n+1}$ . Dann gilt  $\lim_{n \rightarrow \infty} \int f_n d\mu = \int \lim_{n \rightarrow \infty} f_n d\mu$ .

### Dominante Konvergenz / Satz von Lebesgue

Sei  $g: \Omega \rightarrow [0, \infty]$   $\mu$ -integrierbar und  $f: \Omega \rightarrow \mathbb{R}$ ,  $\{f_k\}_{k \in \mathbb{N}}: \Omega \rightarrow \mathbb{R}$   $\mu$ -messbar.

Angenommen  $|f_k| \leq g$  und  $f_k \xrightarrow{k \rightarrow \infty} f$   $\mu$ -fast-everywhere. Dann folgt daraus:

$$\text{i) } \lim_{k \rightarrow \infty} \int |\f_k - f| d\mu = 0 \quad \text{ii) } \lim_{k \rightarrow \infty} \int f_k d\mu = \int f d\mu$$

### Gegenbeispiel

Warum ist es wichtig, dass die Folge  $f_n$  von  $g$  majorisiert/dominiert wird ( $|f_n| \leq g$ ) um den Limes ins Integral zu ziehen?

Wir betrachten die Folge  $f_n(x) = \frac{1}{2^n} \cdot \mathbf{1}_{[n, n]}(x)$ .  $f_n$  konvergiert punktweise gegen  $f = 0$ .

$\int f_n d\lambda = 1 \quad \forall n \in \mathbb{N}$ . Also existiert eine Verteilungsfkt.  $F_n(x)$  zu  $f_n$ . Würden wir nun den Limes einfach ins Integral ziehen dürfen (ohne Einschränkungen), bekämen wir  $\int f d\lambda = \int \lim_{n \rightarrow \infty} f_n d\lambda = \lim_{n \rightarrow \infty} \int f_n d\lambda = \lim_{n \rightarrow \infty} 1 = 1$ . Also hätte  $f = 0$  eine Verteilungsfkt.  $F(x)$ . Offensichtlich ist das aber schwachsinn, denn  $\int f d\lambda = \int 0 d\lambda = 0$ .

Beweis wäre, dass  $\sum_{n=1}^{\infty} \frac{1}{2^n} = \infty$  ergibt.

Es ist hier auch ersichtlich, dass es kein  $\lambda$ -intbares  $g: \Omega \rightarrow [0, \infty]$  gibt, s.d.  $\forall n \in \mathbb{N}: 0 \leq |f_n| \leq g$  gilt.

# Dichte

### Lemma

$\nu: \mathcal{F} \rightarrow \mathbb{R}$ ,  $\nu(A) = \int f d\nu$  ist ein Maß und  $\int g d\nu = \int g \cdot f d\nu$

### Absolute Stetigkeit von Maßen

Sind  $\nu$  und  $\mu$  zwei Maße auf  $(\Omega, \mathcal{F})$ , so heißt  $\nu$  absolut stetig bezüglich  $\mu$ , wenn  $\forall A \in \mathcal{F}$  gilt:

$\mu(A) = 0 \Rightarrow \nu(A) = 0$ . Notation:  $\nu \ll \mu$  ( $\nu$  dominiert  $\mu$ ).

### Satz von Radon-Nikodým / Dichte

Ist  $(\Omega, \mathcal{F}, \mu)$  ein Maßraum mit  $\sigma$ -endlichen Maßen  $\mu$  und  $\nu$ . Wenn  $\nu \ll \mu$ , dann existiert eine messbare Fkt.  $f: \Omega \rightarrow \mathbb{R}$ , s.d.  $\forall A \in \mathcal{F}: \nu(A) = \int_A f d\mu$ . Notation:  $\nu = f \circ \mu$

Die Funktion  $f$  ist eindeutig bis auf eine  $\mu$ -Nullmenge. D.h. Sei  $g$  eine Fkt. mit obigen Eigenschaften, dann gilt  $g = f$   $\mu$ -fast-sicher.

$f$  wird auch geschrieben als  $\frac{d\nu}{d\mu}$  und wird Radon-Nikodým-Ableitung genannt.

Wir nennen  $f$  auch Wahrscheinlichkeitsdichte von einer  $\mathbb{P}V$  bzgl.  $\mu$ .

### Satz

Sei  $(\Omega, \mathcal{F}, \mathbb{P})$  ein W-raum. Sei  $\mu$  ein Maß mit  $\mathbb{P} \ll \mu$ . Dann existiert die Dichte  $f$  mit  $\mathbb{P} = f \circ \mu$  (Dichte der Verteilung  $\mathbb{P}$ ). Sei  $F = \mathbb{B}$ , dann gilt  $F(x) = \mathbb{P}[-\infty, x] = \int_{-\infty, x} f d\mu$

> Diskrete Verteilungen werden von  $\mu = \mu_2$  dominiert.

> (Absolut-)stetige Verteilungen werden von  $\mu = \lambda$  dominiert.

### Beispiel für gemischte Verteilung

Von der verkauften Ware verursacht der Anteil  $\alpha > 0$  keine Kosten und der Rest verursacht exponentialverteilte Kosten mit Erwartungswert  $\beta$ . Wie sind die Kosten verteilt?

$\mathbb{P}\{\omega\} = \alpha$ ,  $\mathbb{P}$  ist auf  $\mathbb{R}^+$  absolut stetig.  $\mathbb{P}$  wird nicht von  $\lambda$  dominiert, da  $\mathbb{P}(B) = \alpha > 0 = \lambda(\{\omega\})$ .

$\mathbb{P}$  wird nicht von  $\mu_2$  dominiert, da  $\mu_2$  nicht  $\sigma$ -endlich auf  $(\mathbb{R}, \mathcal{B})$  ist.

Wir wählen  $\mu = \lambda + \delta_0$ .  $\mu$  ist  $\sigma$ -endlich und dominiert  $\mathbb{P}$ : Sei  $B \in \mathcal{B}$  eine  $\mu$ -Nullmenge, dann  $\lambda(B) + \delta_0(B) = 0$

und somit  $\lambda(B) = \delta_0(B) = 0$ . Offensichtlich ist  $\{\omega\} \notin B$ . Somit folgt  $\mathbb{P}(B) = \int_B f d\lambda = 0$ . Also gilt  $\mu(B) = 0 \Rightarrow \mathbb{P}(B) = 0$ .

somit gilt  $\mathbb{P} \ll \mu$  und daher existiert  $f^* \in \mathbb{M}^*$ , s.d.  $\mathbb{P}(A) = \int_A f^* d\mu \quad \forall A \in \mathcal{B}$ . Dieses  $f^*$  konstruieren wir durch

$$f^*(x) = \begin{cases} (1-\alpha)f(x), & x \neq 0 \\ \alpha, & x = 0 \end{cases}$$

# Diskrete Verteilungen

### Diskreter Wahrscheinlichkeitsraum

Sei  $(\Omega, \mathcal{F}, \mathbb{P})$  ein Wahrscheinlichkeitsraum. Gibt es eine abzählbare Menge  $T \subset \mathcal{F}$  mit  $\mathbb{P}(T) = 1$ ,

so heißt

- $(\Omega, \mathcal{F}, \mathbb{P})$  diskreter Wahrscheinlichkeitsraum

- $\mathbb{P}$  diskretes W-Maß

- $T$  abzählbarer Träger von  $\mathbb{P}$  !  $\Omega$  muss nicht abzählbar sein.

### Zähldichte

$f: \Omega \rightarrow [0, 1]$ ,  $f(\omega) = \mathbb{P}(\{\omega\}) \cdot I_T(\omega)$

heißt Zähldichte.

$$\mathbb{P}(A) = \sum_{\omega \in A} f(\omega) \quad \forall A \in \mathcal{F}$$

# Stetige Verteilungen

### Stetig verteilte ZV

Eine reelle ZV  $X$  heißt stetig verteilt, wenn es eine nicht-negative Borel-messbare Fkt.  $f: \mathbb{R} \rightarrow \mathbb{R}$  mit der Eigenschaft  $\int_{\mathbb{R}} f(t) dt = 1$  gibt, so dass  $\mathbb{P}_X(B) = \mathbb{P}(X \in B) = \int_B f(t) dt$ ,  $B \in \mathcal{B}$ .

$f$  heißt stetige Dichte (bzgl. des Lebesgue-Maßes) von  $X$  bzw.  $\mathbb{P}_X$ .

!  $f$  muss nicht stetig sein, aber es muss eine stetige Fkt.  $g$  geben, mit  $f = g \cdot J_{(a,b)}$

### Träger

Sei  $\mathbb{P}$  eine (beliebige) Verteilungen mit Dichte  $f(x)$ , dann ist  $T = \{x \in \Omega \mid f(x) > 0\}$  der Träger der Verteilung.

### Dichte transformationssatz

Sei  $X: \Omega \rightarrow \mathbb{R}$  eine ZV mit stetiger Verteilungsfkt.  $F_X$  und Dichte  $f_X(x) = \frac{dF_X(x)}{dx}$  bzgl. des  $\lambda$ -Maßes. Sei  $g: \mathbb{R} \rightarrow \mathbb{R}$  bijektiv und stetig diff. bar mit  $g'(x) \neq 0$ . Dann hat  $g \circ X$  die Dichte  $f_{g \circ X}(y) = f_X(g^{-1}(y)) \cdot |g'(g^{-1}(y))|$

# Wichtige parametrische Verteilungen

## Diskrete parametrische Verteilungen

### Bernoulli - Verteilung

Wahrscheinlichkeit für Erfolg / Misserfolg.

$X$  ist Bernoulli verteilt  $X \sim \text{B}(\pi)$ , wenn

$$P_{\pi}(X=x) = \pi^x \cdot (1-\pi)^{1-x} \quad \text{für } x \in \{0, 1\}$$

Dann ist  $F_X(x) = 1 - \pi$ , für  $x \in [0, 1]$

### Diskrete Gleichverteilung

Laplace Wahrscheinlichkeiten

$X$  ist diskret gleichverteilt  $X \sim U_0(a, b)$ , wenn

$$T_X = \{x_1, \dots, x_n\} \subseteq [a, b] \quad \text{und}$$

$$P_{a,b}(X=x) = \frac{1}{b-a} \quad \forall x \in T_X$$

$$\text{Dann ist } F_X(x) = \sum_{i=1}^{x-1} x_{(i)} \quad \text{für } x \in [x_{(k)}, x_{(k+1)})$$

### Geometrische - Verteilung (Variante A)

Wahrscheinlichkeit das man genau  $x$  Versuche für den ersten Erfolg benötigt.  $X$  ist geometrisch verteilt mit  $X \sim G(\rho)$ .

$$P_{\pi}(X=x) = (1-\pi)^{x-1} \cdot \pi, \quad x \in \mathbb{N}^+, \pi \in (0, 1)$$

$$\text{Dann ist } F_X(x) = 1 - (1-\pi)^{\lfloor x \rfloor}, \quad \text{für } x \in [1, +\infty)$$

### Geometrische - Verteilung (Variante B)

Wahrscheinlichkeit  $k$  Fehlversuche vor dem ersten Erfolg zu haben.  $X$  ist geometrisch verteilt mit  $X \sim G(\rho)$ .

$$P_{\pi}(X=k) = (1-\pi)^k \cdot \pi, \quad k \in \mathbb{N}_0, \pi \in (0, 1)$$

$$\text{Dann ist } F_X(x) = 1 - (1-\pi)^{\lfloor x \rfloor + 1}, \quad \text{für } x \in [0, +\infty)$$

## Binomial - Verteilung

Wahrscheinlichkeit für  $x$  Erfolge bei  $n$

Bernoulli - Versuchen.

$X$  ist Binomial - verteilt  $X \sim \text{B}(n, \pi)$ , wenn

$$P_{n,\pi}(X=x) = \binom{n}{x} \cdot \pi^x \cdot (1-\pi)^{n-x}, \quad \text{für } x \in \mathbb{N}_0$$

$$\text{Dann ist } F_X(x) = \sum_{k=0}^{\lfloor x \rfloor} P_{n,\pi}(X=k), \quad \text{für } x \geq 0$$

### Hypergeometrische Verteilung

Wahrscheinlichkeit für  $x$  Erfolge beim "ziehen" von  $n$

Elementen aus einer Stichprobe der Größe  $N$ , wobei es insgesamt  $M$  günstige Elemente gibt.

$X$  ist hypergeometrisch verteilt  $X \sim H(N, M, n)$ , wenn

$$P_{N,M,n}(X=x) = \frac{\binom{M}{x} \cdot \binom{N-M}{n-x}}{\binom{N}{n}}, \quad \text{für } x \in \{\max\{0, n-(N-M)\}, \dots, \min\{n, M\}\}$$

$$\text{Dann ist } F_X(x) = \sum_{k=0}^{\lfloor x \rfloor} P_{N,M,n}(X=k) \cdot \mathbf{1}_{[0, \infty)}$$

### Poisson - Verteilung

Wahrscheinlichkeit für  $x$  Erfolge innerhalb eines Zeitintervalls, wobei  $\lambda > 0$  die Rate ist, mit der Erfolge in diesem Zeit-intervall auftreten.

$X$  ist Poisson - verteilt  $X \sim P(\lambda)$ , wenn

$$P(X=x) = \frac{\lambda^x}{x!} \cdot e^{-\lambda}, \quad \text{für } x \in \mathbb{N}_0$$

$$\text{Dann gilt } F_X(x) = \sum_{k=0}^{\lfloor x \rfloor} P(X=k) = \frac{\Gamma(\lfloor x \rfloor + 1, \lambda)}{\lfloor x \rfloor !}$$

### Satz

Verteilung	$E(X)$	$\text{Var}(X)$
$\text{B}(n, \pi)$	$n \cdot \pi$	$n \cdot \pi \cdot (1-\pi)$
$\text{P}_1(\pi) \text{ (A)}$	$\frac{1}{\pi}$	$\frac{1-\pi}{\pi^2}$
$\text{P}_2(\pi) \text{ (B)}$	$\frac{1-\pi}{\pi}$	$\frac{1-\pi}{\pi^2}$
$U_0(a, b)$	$\frac{a+b}{2}$	$\frac{(b-a+1)^2 - 1}{12}$
$H(N, M, n)$	$n \cdot \frac{M}{N}$	$n \cdot \frac{M}{N} \cdot \frac{N-M}{N} \cdot \frac{N-n}{N-1}$
$P(\lambda)$	$\lambda$	$\lambda$

## Stetige parametrische Verteilungen

### Stetige Gleichverteilung

$X$  ist stetig gleichverteilt  $X \sim U(a, b)$ , wenn

$$f_{a,b}(x) = \frac{1}{b-a} \cdot \mathbf{1}_{[a,b]}(x).$$

$$\text{Dann gilt } F_X(x) = \frac{x-a}{b-a} \cdot \mathbf{1}_{[a,b]}(x) + \mathbf{1}_{[b,+\infty)}(x)$$

### Gammaverteilung

Verallgemeinerung der Exp - Verteilung. Die Gamma - Verteilung ist die Maximum - Entropie - Wahrscheinlichkeitsdichte für

eine ZV  $X$  mit  $E(X) = \frac{\alpha}{\beta} > 0$  und  $E(\ln(X)) = \frac{d \ln(\Gamma(\alpha))}{dx} \Big|_{x=0} - \ln(\beta)$

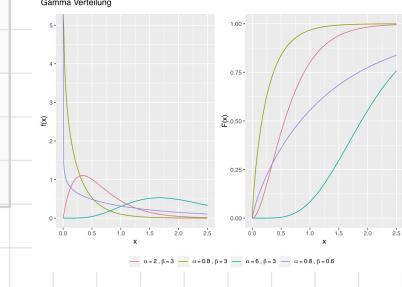
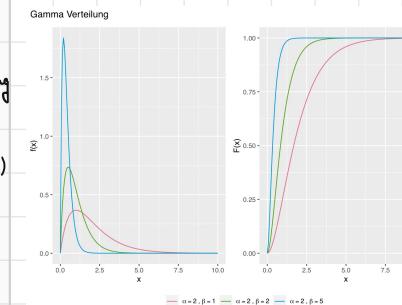
$X$  ist Gamma - verteilt  $X \sim G(\alpha, \beta) \sim \Gamma(\alpha, \beta)$ , wenn

$$f_{\alpha,\beta}(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} \cdot e^{-\beta x} \cdot \mathbf{1}_{[0, \infty)}(x). \quad \Gamma \text{ ist die Gammafunktion:}$$

$$\Gamma(\alpha) = \int_0^{\infty} t^{\alpha-1} e^{-t} dt. \quad \text{Insbesondere } \Gamma(x+1) = x! \quad \forall x \in \mathbb{N}_0.$$

$$\text{Dann gilt } F_X(x) = \frac{1}{\Gamma(\alpha)} \cdot \int_0^x t^{\alpha-1} \cdot e^{-t} \cdot \mathbf{1}_{[0, \infty)}(t) dt$$

$$\text{Note: } \text{Exp}(\lambda) = \Gamma(\alpha=1, \beta=\lambda). \quad X^2(d) = \Gamma(\alpha=\frac{d}{2}, \beta=\frac{1}{2})$$



### Betaverteilung

Familie von Verteilungen auf  $[0, 1]$ , parametrisiert durch zwei Parameter  $\alpha, \beta$ .

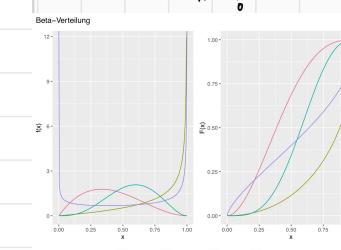
$X$  ist Beta - verteilt  $X \sim \text{Be}(\alpha, \beta)$ , wenn

$$f_{\alpha,\beta}(x) = \frac{1}{B(\alpha, \beta)} x^{\alpha-1} (1-x)^{\beta-1}, \quad \text{für } x \in (0, 1).$$

$B$  ist die Betafunktion und dient zum normieren.

$$B(\alpha, \beta) = \frac{\Gamma(\alpha) \cdot \Gamma(\beta)}{\Gamma(\alpha + \beta)} = \int_0^1 x^{\alpha-1} (1-x)^{\beta-1} dx$$

$$\text{Dann gilt } F_X(x) = \frac{1}{B(\alpha, \beta)} \cdot \int_0^x t^{\alpha-1} (1-t)^{\beta-1} dt$$



## Normalverteilung

$X$  ist normalverteilt  $X \sim N(\mu, \sigma^2)$  mit  $E(X) = \mu$  und  $\text{Var}(X) = \sigma^2$ , wenn

$$f_{\mu, \sigma^2}(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \cdot \exp\left(-\frac{1}{2} \cdot \frac{(x-\mu)^2}{\sigma^2}\right), \text{ für } x \in \mathbb{R}.$$

Eine geschlossene Form für  $F_X(x)$  existiert nicht  $\Rightarrow$  numerische Integration.

Für  $\mu=0$  und  $\sigma^2=1$  nennen wir  $X \sim N(0,1)$  standardnormalverteilt.

Für  $F_X(x)$  wird dann meist als  $\Phi(x)$  notiert, wobei sich diese Werte

in Tabellen finden lassen.

! Linearität:  $X \sim N(\mu, \sigma^2)$ ,  $Y = aX + b \Rightarrow Y \sim N(a\mu + b, a^2\sigma^2)$

$\Rightarrow$  Es gilt außerdem  $X \sim N(\mu, \sigma^2) \Rightarrow \frac{X-\mu}{\sigma} \sim N(0, 1)$ .

Additivität: Seien  $X_1, \dots, X_n$  stoch. unabhängig mit  $X_i \sim N(\mu_i, \sigma_i^2)$  für  $i=1, \dots, n$

$$\text{i)} \sum_{i=1}^n X_i \sim N\left(\sum_{i=1}^n \mu_i, \sum_{i=1}^n \sigma_i^2\right) \quad (\text{umkehrung gilt auch})$$

$$\text{ii)} \text{ Sind alle } \mu_i \text{ gleich } \mu \text{ und alle } \sigma_i^2 = \sigma^2, \text{ dann gilt } \bar{X} = \frac{1}{n} \cdot \sum_{i=1}^n X_i \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

!  $t$ -Verteilung und Invers-Gamma-Verteilung hat nicht mehr reingepasst. Siehe dafür Folien/Skript.

## Dichtetransformationssatz

### Transformationssatz (für monotone Transformationen)

Sei  $X$  eine ZV mit Dichte  $f_X(x)$  und der stetigen Verteilung  $F_X(x)$ .

Sei  $Y = g(X)$  eine streng monotonen und differenzierbare

Fkt. auf  $X$  mit  $g'(x) > 0$ . Dann hat  $Y$  eine Dichtefunktion  $f_Y(y)$ :

$$f_Y(y) = f(g^{-1}(y)) \cdot \left| \frac{1}{g'(g^{-1}(y))} \right| = f(g^{-1}(y)) \cdot |(g^{-1})'(y)|$$

und es gilt  $F_Y(y) = F_X(g^{-1}(y))$

### Inversions Methode

Die Inversionsmethode ist ein Simulationsverfahren, um aus gleichverteilten Zufallszahlen andere Wahrscheinlichkeitsverteilungen zu erzeugen.

1. Erzeuge  $u_1, \dots, u_n$  mit  $u_i \stackrel{iid}{\sim} U(0,1)$ .

2. Berechne  $x_i = F_X^{-1}(u_i)$ ,  $i=1, \dots, n$

Die  $x_i$  sind dann Zufallszahlen aus der gewünschten Verteilung  $F_X(x)$ .

## Cauchy-Verteilung

Verteilung von Verhältnis (ratio) zweier unabhängiger normalverteilter ZV mit Erwartungswert 0.  $X$  ist Cauchy-verteil  $X \sim C$ , wenn

$$f(x) = \frac{1}{\pi} \cdot \frac{1}{1+x^2}, \text{ für } x \in \mathbb{R}.$$

$$\text{Dann gilt } F_X(x) = \frac{1}{2} + \frac{\arctan(x)}{\pi}$$

Note: Sehr viel Wahrscheinlichkeitsmasse in den "Tails". Momente sind undefiniert.

## Satz

Verteilung	$E(X)$	$\text{Var}(X)$
$U(a,b)$	$\frac{1}{2} (a+b)$	$\frac{1}{12} \cdot (b-a)^2$
$\text{Exp}(\lambda)$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$
$\Gamma(\alpha, \beta)$	$\frac{\alpha}{\beta}$	$\frac{\alpha^2}{\beta^2}$
$\text{Be}(\alpha, \beta)$	$\frac{\alpha}{\alpha+\beta}$	$\frac{\alpha\beta}{(\alpha+\beta)^2 \cdot (\alpha+\beta+1)}$
$N(\mu, \sigma^2)$	$\mu$	$\sigma^2$
$C$	nicht existent	nicht existent
$\text{Wei}(\lambda, k)$	$\lambda^k \cdot \Gamma(1 + \frac{k}{\lambda})$	$\lambda^2 \cdot (\Gamma(1 + \frac{2}{\lambda}) - \Gamma(1 + \frac{1}{\lambda}))$

## Survivorfunktion und Hazardrate

Sei  $T$  eine stetige, nicht-negative ZV (Wartezeit auf ein Ereignis). Dann ist

$S(t) := P(T \geq t) = 1 - F_T(t)$  die Survivorfunktion (Wahrscheinlichkeit bis Zeitpunkt  $t$  zu überleben) und  $h(t) := \lim_{\Delta t \rightarrow 0} \frac{P(T \geq t + \Delta t | T \geq t)}{\Delta t} = \frac{f(t)}{S(t)}$  die Hazardrate (Likelihood / "Wahrscheinlichkeit", dass das Ereignis im nächsten Moment eintritt).

## Weibull-Verteilung

Beschreibung von Lebensdauer und Ausfallhäufigkeit von (mechanischen) Objekten.

$X$  ist Weibull-verteil  $X \sim \text{Wei}(\lambda, k)$  mit Parametern  $\lambda$  und  $k$ , wenn

$$f_{\lambda, k}(x) = \lambda k \cdot (\lambda x)^{k-1} \cdot e^{-(\lambda x)^k} \cdot \mathbb{1}_{\mathbb{R}^+}(x).$$

Dann gilt:

$$F_{\lambda, k}(x) = (1 - e^{-(\lambda x)^k}) \cdot \mathbb{1}_{\mathbb{R}^+}(x)$$

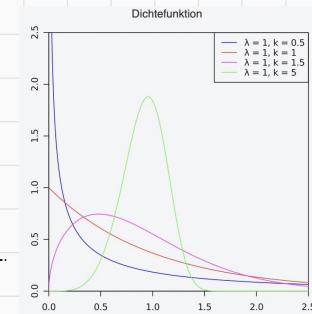
Für  $T \sim \text{Wei}(\lambda, k)$  ist für  $t > 0$   $h(t) = \lambda k \cdot (\lambda t)^{k-1}$

! Der Formparameter  $k > 0$  beschreibt das zeitliche Verhalten der Ausfälle.

$k < 1$ : Trübung (z.B. Kinderkrankheiten)

$k=1$ : Exp.-Verteilung (zufällige Ausfälle)

$k > 1$ : Ermüdungs- und Verschleißausfälle nach langer Nutzung



## Beispiel

$X \sim N(0, 1)$  und  $Y = X^2$ .

$$f_X(x) = \frac{1}{\sqrt{2\pi}} \cdot \exp\left(-\frac{x^2}{2}\right) \quad A_0 = \{-\infty, 0\}, A_1 = (-\infty, 0), A_2 = (0, +\infty)$$

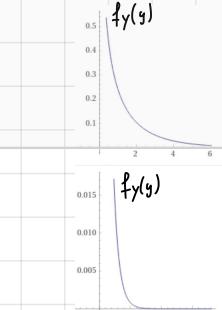
$$g_1: A_0 \rightarrow \mathbb{R}^+, x \mapsto x^2 \quad g_2: A_2 \rightarrow \mathbb{R}^+, x \mapsto x^2$$

$$g_1^{-1}(y) = -\sqrt{y} \quad g_2^{-1}(y) = \sqrt{y}$$

$$f_Y(y) = f_X(-\sqrt{y}) \cdot \left| \frac{1}{-2\sqrt{y}} \right| + f_X(\sqrt{y}) \cdot \left| \frac{1}{2\sqrt{y}} \right| = \frac{1}{\sqrt{2\pi y}} \cdot \exp\left(-\frac{y}{2}\right), \text{ für } y > 0 \\ = 0, \text{ sonst}$$

$$\int_0^{\infty} f_Y(y) dy = 1 \quad \checkmark$$

$$Y \sim \text{P}(\frac{1}{2}, \frac{1}{2})$$



### Transformationssatz (für nicht monotone Transformationen)

Sei  $X$  eine ZV mit Dichte  $f_X(x)$  und der stetigen Verteilung  $F_X(x)$ .

Sei  $Y = g(X)$ . Angenommen es existiert eine Partition  $A_0, A_1, \dots, A_K$  von  $X$ , s.d.

$P(X \in A_0) = 0$  und  $f_X(x)$  stetig auf allen  $A_i$  ist. Angenommen es existieren  $g_1(x), \dots, g_K(x)$

Fkt. entsprechend definiert auf  $A_1, \dots, A_K$ , für die gilt:

i)  $g(x) = g_i(x)$   $\forall x \in A_i$  ii)  $g_i(x)$  ist streng monoton auf  $A_i$  iii)  $g_i(A_i) = T_Y \quad \forall i$

iv)  $g_i'$  ist stetig differenzierbar auf  $Y$  ( $g_i'(x) \neq 0 \quad \forall x \in A_i$ )

Dann hat  $Y$  eine Dichtefunktion  $f_Y(y)$  mit:

$$f_Y(y) = \sum_{i=1}^K f(g_i^{-1}(y)) \cdot \left| \frac{1}{g_i'(g_i^{-1}(y))} \right| = \sum_{i=1}^K f(g_i^{-1}(y)) \cdot |(g_i^{-1})'(y)|, \quad \forall y \in T_Y \\ = 0, \quad y \notin T_Y$$

$$\text{und es gilt } F_Y(y) = \sum_{i=1}^K F_X(g_i^{-1}(y))$$

# Momente (Theorie)

## Momente

Sei  $X$  eine int. bare ZV,  $n \in \mathbb{N}$ , s.d.

$X^n$  quasi-int. bar ist. Dann heißt

## Erwartungswert

Ist  $\Omega \rightarrow \mathbb{R}$  eine quasi-int.bare ZV, so heißt

$$m_n(X) := E[X^n] = \int X^n dP = \int x^n dP(x)$$

Erwartungswert von  $X$  ( $1$ -tes Moment).

## Satz

$$\text{Sei } P_X(A) = \int f_X d\mu, \text{ dann ist } E[X] = \int X dP = \int x dP_X = \int x \cdot f_X d\mu = \begin{cases} \sum_{x \in \Omega} x \cdot f_X(x), & \text{wenn } \mu = \mu_\Sigma \\ \int_0^\infty x f_X(x) dx, & \text{wenn } \mu = \lambda \end{cases}$$

$$E[g(X)] = \int g \circ X dP = \int g dP_X = \begin{cases} \sum_{x=0}^{\infty} g(x) f_X(x), & \text{IP diskret} \\ \int g(x) f_X(x) dx, & \text{IP stetig} \end{cases}$$

## Eigenschaften von $E[X]$

Analog zum Lebesgue-Integral:

$$(i) E\left[\sum_{i=1}^n a_i X_i\right] = \sum_{i=1}^n a_i E[X_i] \quad (ii) X \leq Y \Rightarrow E[X] \leq E[Y]$$

(iii) Sind  $X_1, \dots, X_n$  unabhängige int. bare ZV, so gilt:

$$E\left[\prod_{i=1}^n X_i\right] = \prod_{i=1}^n E[X_i]$$

## Kovarianz / Korrelation

Seien  $X, Y: \Omega \rightarrow \mathbb{R}$  zwei ZV mit  $\text{Var}[X] > 0$

und  $\text{Var}[Y] > 0$ , dann ist die Kovarianz

$$\text{Cov}(X, Y) := E[(X - E(X))(Y - E(Y))]$$

$$\text{die Korrelation } \rho(X, Y) := \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)} \sqrt{\text{Var}(Y)}}$$

! Unabhängig  $\Leftrightarrow$  Unkorreliert

$$|\rho(X, Y)| = 1 \Leftrightarrow Y = a + bX, a, b \in \mathbb{R}$$

## Varianz

Ist  $X$  eine ZV mit  $E[|X|] < \infty$ , so heißt

$$m_2^{(o)}(X) := \text{Var}[X] := E[(X - E(X))^2]$$

Varianz von  $X$  ( $2$ -tes zentriertes Moment)

## Verschiebungssatz

$$\text{Var}[X] = E[X^2] - E[X]^2$$

! Insbesondere gilt also  $E[X]^2 \leq E[X^2]$

## Eigenschaften von $\text{Var}[X]$

$$\text{Var}[aX + b] = a^2 \cdot \text{Var}[X]$$

## Spezialfall Beispiel

$$\text{Var}[X] = 0 \Rightarrow X = E[X] \text{ bzw. } X \sim \delta_{E[X]}$$

## Schiefe

Ist  $X^3$  quasi-int. bar, dann heißt

$$\gamma(X) := \frac{m_3^{(o)}(X)}{m_2^{(o)}(X)^{3/2}} = \frac{E((X - E(X))^3)}{\sqrt{\text{Var}(X)^3}}$$

Schiefe von  $X$ .

## Kurtosis

Ist  $X^4$  quasi-int. bar, dann heißt

$$K(X) := \frac{m_4^{(o)}(X)}{m_2^{(o)}(X)^2} = \frac{E((X - E(X))^4)}{\text{Var}(X)^2} = \frac{E((X - E(X))^4)}{E((X - E(X))^2)^2}$$

Kurtosis von  $X$ .

## Symmetrische Verteilung

## Eigenschaften symmetrischer Verteilungen

Sei  $P$  eine Verteilung auf  $(\mathbb{R}, \mathcal{B})$ .

$P$  heißt symmetrisch um  $a \in \mathbb{R}$ , wenn

$$P((-\infty, a-x]) = P([a+x, \infty)) \quad \forall x \in \mathbb{R}$$

Sei  $P$  eine symmetrische Verteilung auf  $(\mathbb{R}, \mathcal{B})$ .  $X \sim P_X = P$  und  $g$  eine int. bare Fkt. Dann gilt:

$$(i) g \text{ int. bar} \Rightarrow \int g dP_X = \int g(2a-x) dP_X$$

$$(ii) m_n(X) = a \quad (iii) m_{2n+1}^{(o)}(X) = 0 \quad \forall n \in \mathbb{N} \quad (iv) a \text{ ist Median von } X$$

## Modus

Gegeben sei eine eindim. ZV  $X$  mit Verteilung  $P_X$  und Dichte  $f(x)$ .

$m$  heißt Modus von  $X$  bzw.  $P$ , wenn  $f(m)$  ein lok. Max. von  $f(x)$  ist.

## Median

Gegeben sei eine eindimensionale ZV mit  $X$  mit

Verteilung  $P_X$ .  $m \in \mathbb{R}$  heißt Median von  $P_X$  bzw.  $X$ , wenn

$$P_X([-\infty, m]) \geq 0.5 \text{ und } P_X([m, \infty)) \geq 0.5$$

## Quantile

Gegeben sei eine eindimensionale ZV mit  $X$  mit

Verteilung  $P_X$ .  $q \in \mathbb{R}$  heißt  $p$ -Quantil von  $P_X$  bzw.  $X$ ,

$$\text{wenn } P_X([-\infty, q]) \geq p \text{ und } P_X([q, \infty)) \geq 1-p$$

## Markov- und Chebyshev-Ungleichungen

Sei  $X: \Omega \rightarrow \mathbb{R}$  eine reelle ZV. Dann gilt

$$\forall \varepsilon > 0: P(|X| > \varepsilon) \leq \frac{1}{\varepsilon^2} \cdot E[X^2]$$

$$\text{Markov-Ungleichung (n=1): } P(|X| > \varepsilon) \leq \frac{1}{\varepsilon} \cdot E[|X|]$$

$$\text{Chebyshev-Ungleichung (n=2): } P(|X - E[X]| \geq \varepsilon) \leq \frac{1}{\varepsilon^2} \cdot \text{Var}(X)$$

## $p$ -Norm/ $L^p$ -Raum

Sei  $f: \Omega \rightarrow \mathbb{R}$ ,  $\mathcal{F}$ -meßbar auf  $(\Omega, \mathcal{F}, \mu)$ . Dann heißt

$$\|f\|_p = \left( \int |f|^p d\mu \right)^{1/p} \quad \varepsilon \in [0, \infty) \text{ die } p\text{-Norm von } f.$$

Für  $p \geq 1$  ist der  $L^p$ -Raum

$$L^p := L^p(\Omega, \mathcal{F}, \mu) := \{f: \Omega \rightarrow \mathbb{R} \mid f \text{ } \mathcal{F}\text{-meßbar mit } \|f\|_p < \infty\}$$

## Wahrscheinlichkeitserzeugende Funktion

Für eine ZV  $X: \Omega \rightarrow \mathbb{N}_0$  heißt  $m_X: [0, 1] \rightarrow [0, 1]$  mit

$$m_X(t) := \sum_{k=0}^{\infty} t^k \cdot P(X=k) \text{ die Wahrscheinlichkeitserzeugende Funktion.}$$

! Es gilt  $m_X(t) = E[t^X]$

## Multiplikationsformel

Sind  $X, Y$  unabhängige  $\mathbb{N}_0$ -wertige ZV, so gilt

$$m_{X+Y}(t) = m_X(t) \cdot m_Y(t), \quad t \in \mathbb{R}$$

## Jensen-Ungleichung

Sei  $X$  eine int. bare ZV und  $g: \mathbb{R} \rightarrow \mathbb{R}$  konkav.

Dann gilt  $E[g(X)] \geq g(E[X])$

Ist  $f: \mathbb{R} \rightarrow \mathbb{R}$  konkav, so gilt  $f(E[X]) \geq E[f(X)]$

## Hölder-Ungleichungen

1) Für  $1 < p, q < \infty$  mit  $\frac{1}{p} + \frac{1}{q} = 1$  und  $f, g: \Omega \rightarrow \mathbb{R}$  meßbar gilt  $\|f \cdot g\|_1 \leq \|f\|_p \cdot \|g\|_q$

2) Ist  $\mu(\Omega) < \infty$  und  $p \geq q \geq 1$ , so ist  $L^q \subseteq L^p$  und es gibt  $c > 0$ , s.d.  $\|f\|_p \leq c \cdot \|f\|_q \quad \forall f \in L^q$

3) Sind  $f, g: \Omega \rightarrow \mathbb{R}$  meßbar und  $p \geq 1$ , so gilt  $\|f + g\|_p \leq \|f\|_p + \|g\|_p$

## Beispiel

Sei  $X_i \sim \text{Bin}(1, p)$  und  $Y = \sum_{i=1}^n X_i \sim \text{Bin}(n, p)$ . Dann ist  $m_{X_i}(t) = \sum_{k=0}^{\infty} t^k \cdot P(X_i=k) = 1-p + t \cdot p$ .

$$m_Y(t) = \prod_{i=1}^n m_{X_i}(t) = (1-p + t \cdot p)^n. \quad E[Y] = \lim_{n \rightarrow \infty} n \cdot (1-p + t \cdot p)^{n-1} \cdot p = n \cdot p$$

## Momentenerzeugung

Ist  $X: \Omega \rightarrow \mathbb{N}_0$ , dann gilt:

$$E[X] = \lim_{t \rightarrow 1} \frac{d}{dt} m_X(t)$$

# Mehrdimensionale Momente (benötigt Thema Zufallsvektoren)

## Erwartungswert und Kovarianzmatrix

Sei  $X: \Omega \rightarrow \mathbb{R}^n$ ,  $\underline{X} = (X_1, \dots, X_n)$  eine  $n$ -dim. ZV, dann heißt  
 $E[\underline{X}] = (E[X_1], \dots, E[X_n])$  der ( $n$ -dimensionale) Erwartungswert von  $\underline{X}$ .

$$V[\underline{X}] := E[(\underline{X} - E[\underline{X}]) \cdot (\underline{X} - E[\underline{X}])^T]$$

Anmerkung:  $V[\underline{X}]_{i,j} = \text{Var}[X_i]$ .  $V[\underline{X}]_{i,j} = \text{Cov}(X_i, X_j) = V[\underline{X}]_{j,i}$

!  $V[\underline{X}]$  ist positiv semidefiniert

## Korrelationsmatrix

Sei  $\Sigma$  die Kovarianzmatrix einer mehrdimensionalen ZV  $\underline{X} = (X_1, \dots, X_n)$  und  $\text{diag}(\Sigma)$  die Matrix der Diagonalelemente von  $\Sigma$ . Dann heißt  
 $R := \text{Corr}(\underline{X}) := \text{diag}(\Sigma)^{-\frac{1}{2}} \cdot \Sigma \cdot \text{diag}(\Sigma)^{-\frac{1}{2}}$   
die Korrelationsmatrix von  $\underline{X}$ .

## Standardisierung

Sei  $\underline{X} = (X_1, \dots, X_n)$  ein  $n$ -dim. ZV mit  $E[\underline{X}] = \underline{\mu}$  und positiv definiter Kov. matrix  $\Sigma$ .

Dann existiert eine invertierbare Matrix  $B \in \mathbb{R}^{n \times n}$ , so dass gilt:

Für  $\underline{Y} = B^{-1} \cdot (\underline{X} - \underline{\mu})$  ist  $E[\underline{Y}] = \underline{0}$  und  $V[\underline{Y}] = I_n$

## Satz

Sei  $\underline{X}: \Omega \rightarrow \mathbb{R}^n$  eine  $n$ -dim. ZV.  $A \in \mathbb{R}^{m \times n}$  und  $b \in \mathbb{R}^m$ .

$$(i) E[A\underline{X} + b] = A E[\underline{X}] + b$$

$$(ii) V[A\underline{X} + b] = A \cdot V[\underline{X}] \cdot A^T$$

# Erzeugende Funktion

## Momenterzeugende Funktion

Ist  $X$  eine reelle ZV und  $D := \{s \in \mathbb{R} \mid E[\exp(sX)] < \infty\}$ , so heißt die Fkt.

$$M: D \rightarrow \mathbb{R}, s \mapsto E[\exp(sX)] = \int \exp(sx) dP_X = \int \exp(sx) \cdot f_X(x) dx$$

momenterzeugende Funktion.

## Satz

Sei  $X$  eine ZV mit momenterzeugender Funktion  $M: D \rightarrow \mathbb{R}$ .

Ist  $(-\alpha, \alpha) \subseteq D$  für ein beliebiges  $\alpha > 0$ , so gilt  $\forall n \in \mathbb{N}$ :

$$i) E[X^n] < \infty \quad ii) M(s) = \sum_{n=0}^{\infty} \frac{s^n}{n!} E[X^n] \quad iii) \frac{d^n M}{ds^n}(0) = E[X^n]$$

## Charakteristische Funktion

Sei  $X$  eine ZV. Die Funktion  $\varphi_X: \mathbb{R} \rightarrow \mathbb{C}$  mit

$$\varphi_X(t) := E[\exp(itX)] = \int \exp(itX) dP = \int f_X(x) \cdot \exp(itx) dx$$

heißt charakteristische Fkt. von  $X$ .

## Beispiel

$$i) X \sim B(n, p): \varphi_X(t) = (1 + p - p e^{it})^n$$

$$ii) X \sim \mathcal{F}_0(\lambda): \varphi_X(t) = \exp(-\lambda(1 - e^{it}))$$

$$iii) X \sim \mathcal{U}(0, 1): \varphi_X(t) = \exp(-t^2/2)$$

## Eigenschaften von charakteristischen Funktionen

Seien  $\varphi_X$  und  $\varphi_Y$  charakteristische Funktionen und  $a, b \in \mathbb{R}$ . Dann gilt:

$$i) \text{ Eindeutigkeit: } \varphi_X = \varphi_Y \Leftrightarrow P_X = P_Y$$

iii)  $\varphi_X$  ist eine gleichmäßig stetige Fkt.

iii)  $\varphi_X$  ist  $k$ -te Ableitung.

$$ii) \text{ Linearität: } \varphi_{aX+b}(t) = \exp(itb) \cdot \varphi_X(at)$$

$$iv) E[|X|^k] < \infty \Rightarrow E[X^k] = \frac{\varphi_X^{(k)}(0)}{i^k}$$

## Dichte von $X$ mittels der charakteristischen Fkt.

Sei  $\varphi_X$  eine charakteristische Funktion. Dann gilt: Die Verteilung

$$\text{von } X \text{ hat die Dichte } f_X(x) = \frac{1}{2\pi} \int \exp(-itx) \cdot \varphi_X(t) dt$$

# Momente (Emperie) / Kennwerte & Verteilungeigenschaften

## Lagemaße

### Lagemaßzahlen

- > Wo liegt die Masse, Mitte und Mehrzahl der Daten?
- > Welche Merkmalsausprägung ist typisch für die Verteilung?

### Der Mittelwert (Emperie)

Arithmetisches Mittel:  $\bar{x}_{\text{arith}} := \frac{1}{n} \cdot \sum_{i=1}^n x_i = \frac{1}{n} \cdot \sum_{i=1}^k h_i \cdot a_i = \sum_{i=1}^k f_i \cdot a_i$

- instabil gegenüber Ausreißern
- mindestens intervallskalierte Daten
- + bekanntestes Lagemaß und wichtiger theoretischer Nutzen.

Gewichtetes Mittel:  $\bar{x}_w := \frac{1}{\sum_{i=1}^n w_i} \cdot \sum_{i=1}^n w_i \cdot x_i$ , mit  $w_i \geq 0 \quad \forall i$

Geometrisches Mittel:  $\bar{x}_G := \sqrt[n]{\prod_{i=1}^n x_i} = \exp\left(\frac{1}{n} \sum_{i=1}^n \log(x_i)\right)$ .

- Mindestens Verhältnisskala ( $x_i > 0$ )
- + Anwendbar auf multiplikative Faktoren

Harmonisches Mittel:  $\bar{x}_H := \frac{1}{\frac{1}{n} \cdot \sum_{i=1}^n \frac{1}{x_i}} = \left(\frac{1}{n} \sum_{i=1}^n x_i^{-1}\right)^{-1}$

- Mindestens Verhältnisskala ( $x_i > 0$ )
- + Anwendbar auf Quotienten/Verhältnisse.

Getrimmtes Mittel: Sei  $\alpha \in (0,1)$ ,  $x_{(1)}, \dots, x_{(n)}$  die geordnete Stichprobe und  $r = \max\{f \in \mathbb{Z} | f \leq n, k\}$ .

Wir definieren das  $\alpha$ -getrimmte Mittel als  $\bar{x}_\alpha := \frac{1}{n-2r} \cdot \sum_{i=r+1}^{n-r} x_{(i)}$ .

$\nexists$   $\alpha$ -Anteil der extremsten Werte wird abgeschnitten

Alternativ:  $\bar{x}_\alpha := \frac{1}{n} \cdot \left( \sum_{i=r+1}^{n-r} x_{(i)} + r \cdot \bar{x}_\alpha + r \cdot \bar{x}_{1-\alpha} \right)$   
 $\alpha$ -Quantil

### Quantil/Percentil (Emperie)

$x_{(1)}, \dots, x_{(k)}$  sind die geordneten Werte der Stichprobe.

Das  $p$ -Quantil ( $p \in [0,1]$ ) ist der Wert  $\tilde{x}_p$  für den gilt:

Anteil  $p$  der Daten sind  $\leq \tilde{x}_p$  & Anteil  $1-p$  der Daten sind  $\geq \tilde{x}_p$ .

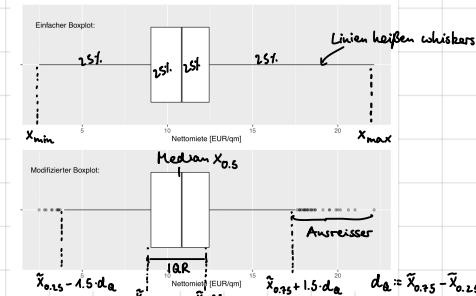
$$\tilde{x}_p := \begin{cases} x_{(k)} & , \text{ falls } n \cdot p \notin \mathbb{N}_0 \text{ und } k > kp \\ \frac{1}{2} \cdot (x_{(k)} + x_{(k+1)}) & , \text{ falls } k = n \cdot p \in \mathbb{N}_0 \end{cases}$$

(Alternativ beliebigen Wert  $\tilde{x}_p \in [x_{(k)}, x_{(k+1)}]$  für  $k = n \cdot p \in \mathbb{N}_0$ )

### Median (Emperie)

$\bar{x}_{\text{med}} := \tilde{x}_{0.5} := 50\%-Perzentil$

- + anschaulich
- + stabil gegenüber monotonen Transformationen
- + geeignet für mindestens ordinalale Daten
- + stabil gegenüber Ausreißern



## Streuungsmaße

### Streuungsmaßzahlen

- > Über welchen Bereich erstrecken sich die Ausprägungen?
- > Wie groß ist die Schwankung der beobachteten Werte?
- > Wie eng beieinander liegen die beobachteten Werte?

### Stichprobenvarianz & Stichprobenstandardabweichung

$$s_x^2 := \frac{1}{n-1} \cdot \sum_{i=1}^n (x_i - \bar{x})^2 \quad . \quad s_x := \sqrt{s_x^2} .$$

- Empfindlich gegen Ausreißer

### Standardabweichung einer 2V

Die Standardabweichung  $\sigma(X)$  einer 2V  $X$  ist definiert als  $\sigma(X) = \sqrt{\text{Var}(X)}$  bzw.  $s_x = \sqrt{s_x^2}$  für Stichproben

## Sätze

Sei  $Y = a + bX$ , für  $a, b \in \mathbb{R}$ . Dann gilt:

$$\sigma_y^2 = b^2 \cdot \sigma_x^2 \quad ; \quad \sigma_y = |b| \cdot \sigma_x \quad ; \quad s_y^2 = b^2 \cdot s_x^2 \quad ; \quad s_y = |b| \cdot s_x$$

### Verschiebungsratz

$$\forall c \in \mathbb{R}: \sum_{i=1}^n (x_i - c)^2 = \sum_{i=1}^n (x_i - \bar{x})^2 + n \cdot (\bar{x} - c)^2$$

$$\stackrel{\text{Def. Var}}{\Rightarrow} \text{Var}(x) = E(X^2) - E(x)^2$$

### Variationskoeffizient

$$v = \frac{\sigma_x}{\bar{x}} \quad \text{mit } \bar{x} > 0.$$

Skalierungsunabhängige Maßzahl für relative Schwankungen um  $\bar{x}$ .

## Streuungszerlegung I

Seien die Daten in  $r$  Schichten aufgeteilt:

$$x_1, \dots, x_{n_1}, x_{n_1+1}, \dots, x_{n_2}, \dots, x_n \text{ mit } n = \sum n_j$$

$$\text{Schichtmittelwerte: } \bar{x}_1 = \frac{1}{n_1} \cdot \sum_{i=1}^{n_1} x_i; \bar{x}_2 = \sum_{i=n_1+1}^{n_2} x_i; \dots$$

$$\text{Schichtvarianz: } \hat{s}_{X_1}^2 = \frac{1}{n_1} \sum_{i=1}^{n_1} (x_i - \bar{x}_1)^2; \hat{s}_{X_2}^2 = \frac{1}{n_2} \sum_{i=n_1+1}^{n_2} (x_i - \bar{x}_2)^2$$

$$\text{Dann gilt: } \hat{s}_X^2 = \frac{1}{n} \cdot \sum_{j=1}^r n_j \cdot \hat{s}_{X_j}^2 + \frac{1}{n} \cdot \sum_{j=1}^r n_j \cdot (\bar{x}_j - \bar{x})^2$$

Gesamtstreuung = Streuung innerhalb der Schichten + Streuung zwischen den Schichten

## Streuungszerlegung der Netto-Quadratmetermiete bezüglich Zimmerzahl:

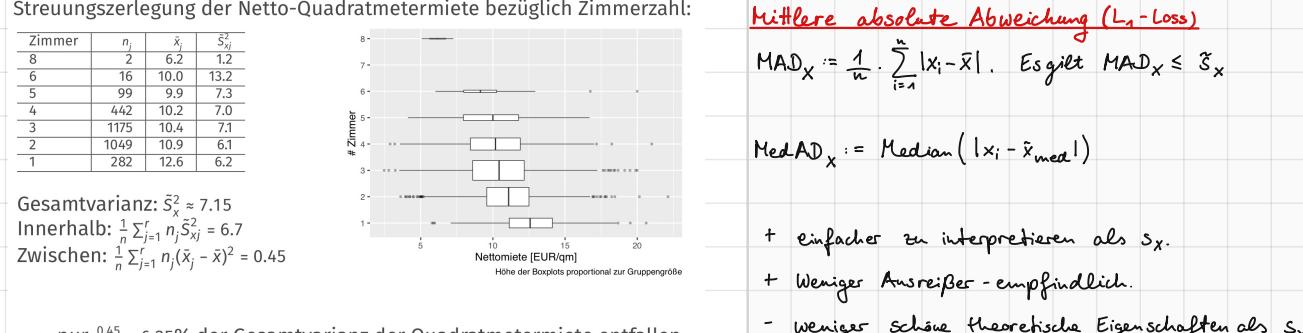
Zimmer	$n_j$	$\bar{x}_j$	$\hat{s}_{X_j}^2$
8	2	6.2	1.2
6	16	10.0	13.2
5	99	9.9	7.3
4	442	10.2	7.0
3	1175	10.4	7.1
2	1049	10.9	6.1
1	282	12.6	6.2

$$\text{Gesamtvarianz: } \hat{s}_X^2 \approx 7.15$$

$$\text{Innerhalb: } \frac{1}{n} \sum_{j=1}^r n_j \hat{s}_{X_j}^2 = 6.7$$

$$\text{Zwischen: } \frac{1}{n} \sum_{j=1}^r n_j (\bar{x}_j - \bar{x})^2 = 0.45$$

$\Rightarrow$  nur  $\frac{0.45}{7.15} = 6.25\%$  der Gesamtvarianz der Quadratmetermiete entfallen auf Unterschiede zwischen Wohnungen mit unterschiedlicher Zimmerzahl.



## Mittlere absolute Abweichung ( $L_1$ -Loss)

$$\text{MAD}_X := \frac{1}{n} \cdot \sum_{i=1}^n |x_i - \bar{x}|. \text{ Es gilt } \text{MAD}_X \leq \hat{s}_X$$

$$\text{MedAD}_X := \text{Median}(|x_i - \bar{x}_{\text{med}}|)$$

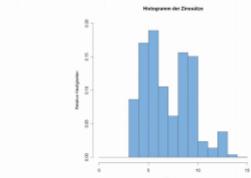
+ einfacher zu interpretieren als  $s_X$ .

+ Weniger Ausreißer-empfindlich.

- Weniger schöne theoretische Eigenschaften als  $s_X$ .

## Verteilungseigenschaften

unimodal = eingipflig, multimodal = mehrgipflig



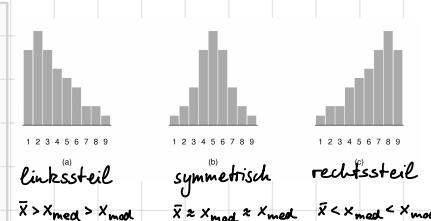
Das Histogramm der Zinssätze zeigt eine bimodale (trimodale...) Verteilung.

### Symmetrie & Schiefe

Symmetrisch  $\Leftrightarrow$  Annähernd spiegelsymm.

linkssteil  $\Leftrightarrow$  Verteilung fällt nach links (rechtsschief) deutlich steiler und nach rechts langsam ab.

rechtssteil  $\Leftrightarrow$  Verteilung fällt nach rechts (linksschief) deutlich steiler und nach links langsam ab.



### Quartilskoeffizient

$$g_p := \frac{(\bar{x}_{1-p} - \bar{x}_{\text{med}}) - (\bar{x}_{\text{med}} - \bar{x}_p)}{\bar{x}_{1-p} - \bar{x}_p}, p \in (0, \frac{1}{2})$$

g.o.s nennt man auch Quartilskoeffizient.

Symmetrisch:  $g_p = 0$

linkssteil:  $g_p > 0$

rechtssteil:  $g_p < 0$

## Fisher's Momentkoeffizient für Schiefe (3. normiertes Moment)

$$g_m = E\left[\left(\frac{(X - E(X))}{\sigma_X}\right)^3\right] = \frac{E[(X - E(X))^3]}{E[(X - E(X))^2]^{\frac{3}{2}}} = \frac{\frac{1}{n} \cdot \sum_{i=1}^n (x_i - \bar{x})^3}{\sigma_X^3} \quad \text{wenn } E(X) < \infty$$

$$= \frac{E(X^3) - 3E(X) \cdot \sigma_X^2 - E(X)^3}{\sigma_X^3}$$

symmetrisch:  $g_m = 0$

linkssteil:  $g_m > 0$

rechtssteil:  $g_m < 0$

$$\text{Corrected: skew } \tilde{g}_m = \frac{n \cdot \sum_{i=1}^n (x_i - \bar{x})^3}{(n-1)(n-2) \cdot \hat{s}_X^3}$$

## Kurtosis (4. normiertes Moment)

$$k_X := \text{Kurt}(X) := E\left[\left(\frac{(X - E(X))}{\sigma_X}\right)^4\right] = \frac{E[(X - E(X))^4]}{E[(X - E(X))^2]^2} = \frac{\frac{1}{n} \cdot \sum_{i=1}^n (x_i - \bar{x})^4}{\sigma_X^4}$$

Exzess-Kurtosis:  $k_X^* = k_X - 3$

mesokurtisch:  $k_X^* \approx 0$

leptokurtisch:  $k_X^* > 0$ . Viele extreme Werte

platykurtisch:  $k_X^* < 0$ . Wenig extreme Werte

$$\text{Sample kurtosis: } \tilde{k} = \frac{n \cdot (n+1)}{(n-1)(n-2)(n-3)} \cdot \frac{\frac{1}{n} \sum (x_i - \bar{x})^4}{\hat{s}_X^4} - \frac{3(n-1)^2}{(n-2)(n-3)}$$

## Konzentrationsmaße

### Lorenzkurve

Das Merkmal darf nur positive Werte annehmen.

$x_{(1)}, \dots, x_{(n)}$  sei die geordnete Stichprobe.

Die Lorenzkurve verbindet Punktpaare bestehend aus den Teilsummen von  $x_{(i)}$  (d.h.  $\sum_{i=0}^k x_{(i)}$ ) und dem relativen Anteil an Individuen, die diese Teilsumme besitzen.

### Berechnung

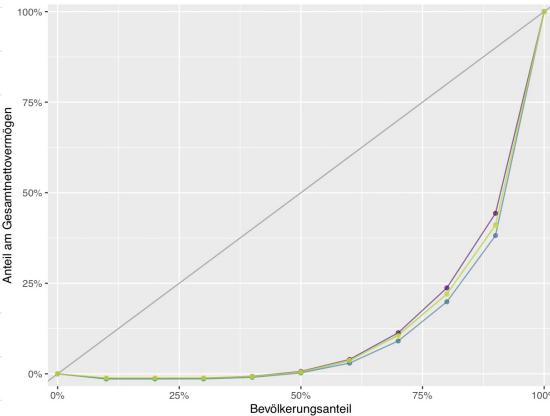
$$U_{(0)} = 0, \quad V_{(0)} = 0, \quad j = 1, \dots, n.$$

$$U_{(j)} := \frac{j}{n} \quad (\text{Aufteilung der } x\text{-Achse})$$

$$V_{(j)} := \frac{\sum_{i=1}^j x_{(i)}}{\sum_{i=1}^n x_{(i)}} \cdot \frac{1}{n} \quad (\text{y-Werte})$$

$V_{(j)}$  ist monoton steigend

Lorenzkurve der individuellen Nettovermögen in Deutschland  
Gini-Koeffizienten: ca. 0.77 - 0.80



### Gini-Koeffizient / Lorenz'sches Konzentrationsmaß

Der Gini-Koeffizient ist eine Maßzahl, die das Ausmaß der Konzentration beschreibt. Er ist definiert als

$$G = 2 \cdot F; \quad G \in [0, \frac{n-1}{n}]$$

wobei  $F$  die Fläche zwischen  $y=x$  und der Lorenzkurve ist.

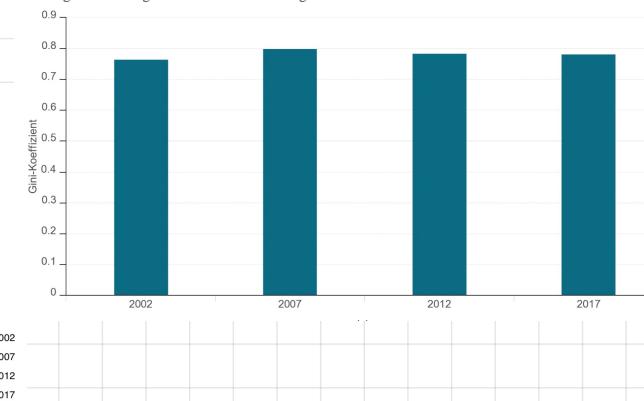
$$G = \frac{2 \cdot \sum_{i=1}^n i \cdot x_{(i)} - (n+1) \cdot \sum_{i=1}^n x_{(i)}}{n \cdot \sum_{i=1}^n x_{(i)}} \quad \text{oder} \quad G = 1 - \frac{1}{n} \sum_{i=1}^n (U_{(i-1)} + V_{(i)}) \\ = \frac{n-1}{n} - \frac{2}{n} \sum_{i=1}^{n-1} V_{(i)}$$

$$\text{Normierter Gini-Koeffizient: } G^+ = \frac{n}{n-1} \cdot G \quad G^+ \in [0, 1]$$

$G^+ = 0$  bedeutet keine Konzentration (Gleichverteilung)

$G^+ = 1$  bedeutet volle Konzentration (Monopol)

Vermögensverteilung individuelle Nettovermögen nach SOEP



### Herfindahl-Index

Seien  $x_1, \dots, x_n$  Daten mit  $x_i \geq 0$ .  $p_i := \frac{x_i}{\sum_j x_j}$

Der Herfindahl-Index ist

$$H := \sum_{i=1}^n p_i^2 \in [\frac{1}{n}, 1]$$

# Statistische Grafiken

## Grammatik von Grafiken

Grafik = Daten + geometrische Elemente + Ästhetische Zuordnung  
 + Datentransformationen + Skalen + Koordinatensysteme  
 + Facettierung + Theme + {Grafik}

Geometrische Elemente = Punkte | Linien | Rechtecke | Boxplots | Dichtefkt. | ...

Ästhetische Zuordnung = Position & Farbe & Größe & Form

Datentransformationen = id | Mittelwerte | Anteile | ...

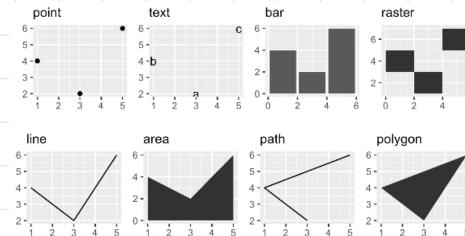
Skalen = Achsenabschnitte & Farbe & Legenden & Achsenbeschriftung & ...

Koordinatensysteme = kartesisch | logarithmisch | Polarkoord. | Kartenproj. | ...

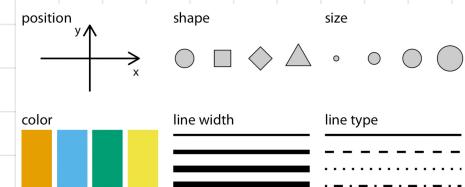
Facettierung = small multiples | lattice plot | plot | ...

Theme = Font & Gitterlinien & Hintergrundfarben & Layout von Text & ...

## Beispiele Geometrien

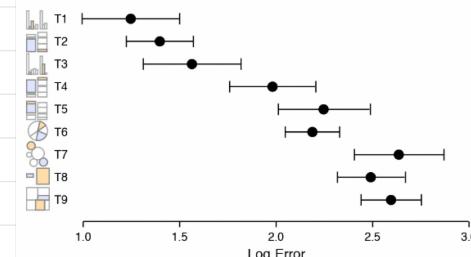


## Beispiele Ästhetiken



## Wahrnehmung von Grafiken

### Crowdsourced Results



Hierarchie der korrekten Interpretation:

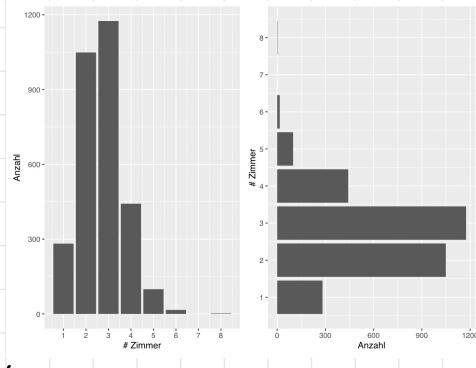
1. Position
2. Abstände / Längen
3. Steigung
4. Winkel
5. Flächen
6. Volumen
7. Farbe (Ton, Helligkeit, Sättigung)

## Goldene Regeln für Grafikgestaltung

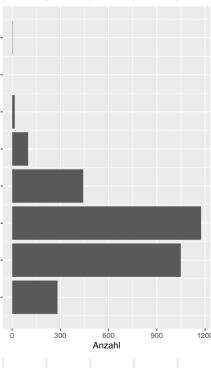
- Kommunikationsabsicht klarmachen
- Lesbarkeit maximieren

## Visualisierung von Häufigkeiten & Verteilungen diskreter Merkmale

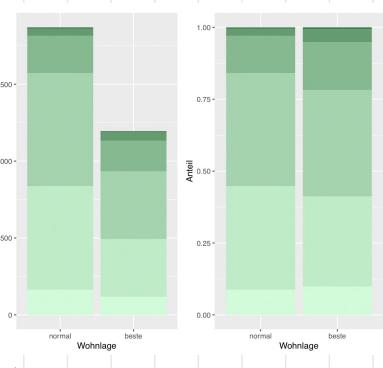
### Säulendiagramm



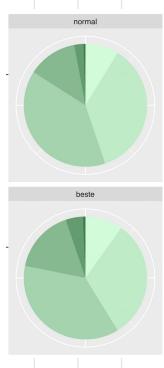
### Balkendiagramm



### Stapeldiagramm (absolut & relativ)



### Kreisdiagramm



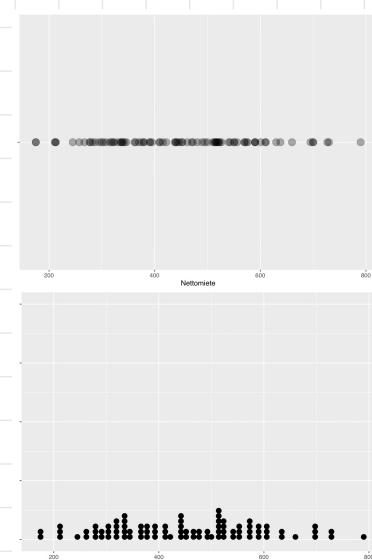
Für ordinale Merkmale, metrische Merkmale mit wenig Ausprägung und nominale Merkmale, wobei die Anordnung beliebig ist. Breite ist beliebig.

Anwendbar für die gleichen Merkmale wie zuvor.  
 Besonders geeignet für den Vergleich verschiedener Gruppen (bedingte Häufigkeiten).

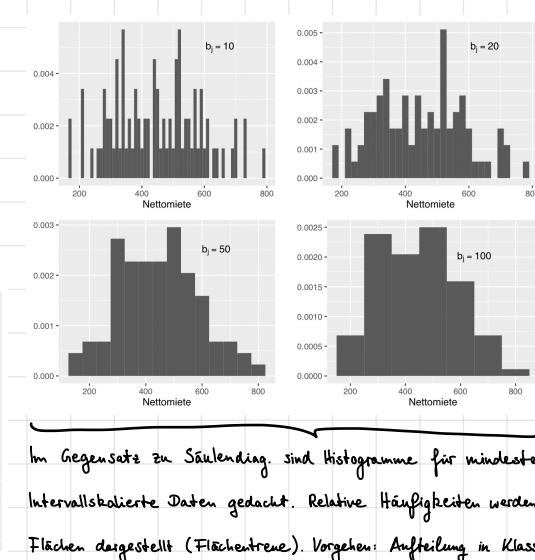
Grundsätzlich schwieriger zu interpretieren als Längendiagramme, aber enthält keine klare Ordnung.

## Visualisierung von Häufigkeiten & Verteilungen metrischer Merkmale

### Dotplots



### Histogramme



Im Gegensatz zu Säulendiag. sind Histogramme für mindestens intervallskalierte Daten gedacht. Relative Häufigkeiten werden durch Flächen dargestellt (Flächentrenne). Vorgehen: Aufteilung in Klassen und Bestimmung der relativen Häufigkeiten  $f_i = \frac{n_i}{n}$ . Höhe  $y_i$  des Balkens bestimmen mittels  $b_i \cdot y_i = f_i$ , wobei  $b_i$  die Breite der Klasse  $i$  ist.

Nachteil: Interpretation der Höhe bei unterschiedlichen Breiten nicht sinnvoll.

- Visueller Eindruck hängt von Klassenbreiten ab.
- Vorsicht bei Rändern.

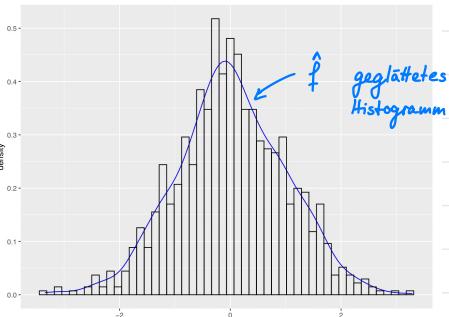
## Kerndichteschätzung

### Kerndichteschätzer

Sei  $K$  eine Kernfunktion, d.h.  $\forall u: K(u) \geq 0$  und  $\int_{-\infty}^{\infty} K(u) du = 1$ .

Dann ist der Kerndichteschätzer (KDE: kernel density estimator) definiert als

$$\hat{f}(x) := \frac{1}{n \cdot h} \sum_{i=1}^n K\left(\frac{x-x_i}{h}\right)$$



Histogramm

Kerndichteschätzung mit Gauss-Kern

### Beziehung zu Fourier-Transformation

For the sample  $(x_1, \dots, x_n)$  the characteristic

function  $\phi(t) = E[e^{itX}]$  can be estimated by

$$\hat{\phi}(t) = \frac{1}{n} \sum_{j=1}^n e^{itx_j}$$

Knowing  $\phi$  we can get the corresponding density func.  $f$  trough the Fourier transform formula. But because  $\hat{\phi}$  is only an estimate and diverges for  $|t| \rightarrow \infty$  we need to "dampen"  $\hat{\phi}$  by multiplying with  $\psi_h(t) = \psi(ht)$ , whereas  $\psi(0) = 1$  and  $\psi(ht) \rightarrow 0$  for  $|t| \rightarrow \infty$ . The bandwidth  $h$  controls the speed of convergence to 0.

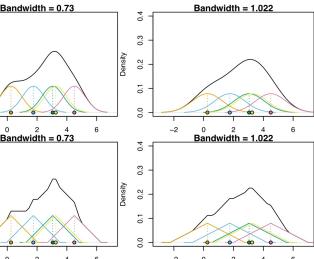
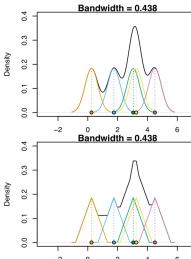
Most common is  $\psi(t) = K_{[-1,1]}$  or  $\psi(t) = e^{-\pi t^2}$ .

$$\hat{f}(x) = \frac{1}{2\pi} \int_{-\infty}^{\infty} \hat{\phi}(t) \cdot \psi_h(t) e^{-itx} dt = \dots = \frac{1}{n \cdot h} \sum_{j=1}^n K\left(\frac{x-x_j}{h}\right)$$

where  $K$  is the Fourier transform of  $\psi$ .

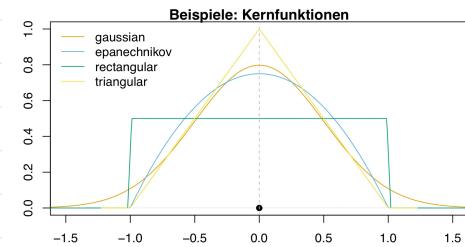
Histogramm

Kerndichteschätzung mit Gauss-Kern



### Beispiele für Kernfunktionen

- Gauß-Kern:  $K(u) = \frac{1}{\sqrt{2\pi}} \exp(-\frac{1}{2}u^2)$
- Epanechnikov-Kern:  $K(u) = \max\{0, \frac{3}{4} \cdot (1-u^2)\}$
- Dreieck-Kern:  $K(u) = \max\{0, 1 - |u|\}$



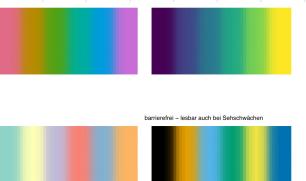
KDE = Histogramm bei größeren Datenmengen oder (quasi-)stetigen Merkmalen.

#### Vorteil:

Kerndichteschätzungen berücksichtigen Entfernung der benachbarten Punkte mit abnehmender Gewichtung über Distanz.

#### Nachteil:

Abhängigkeit von Bandbreite  $h \rightarrow$  Wird aus den Daten bestimmt.



Beispiel qualitative Farbskala

Erster Vokal im Namen

Beispiel sequentielle Farbskala

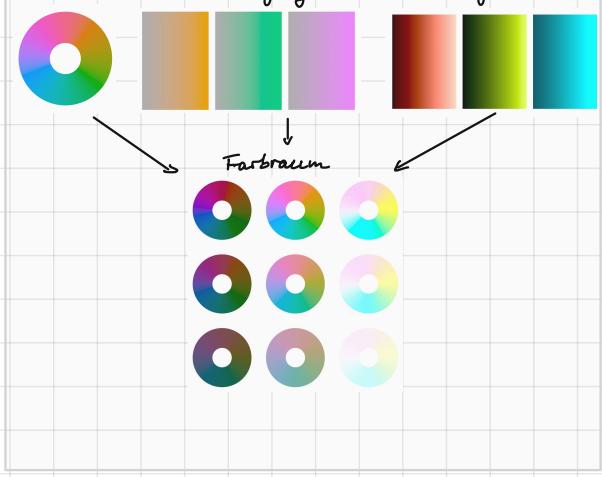


Sinnvoll, aber evtl. kleine Unterschiede verschwimmt

## Farbskalen

### Farbraum

Der Farbraum ist definiert durch die Möglichkeiten für Farbton, Farbsättigung und Helligkeit.

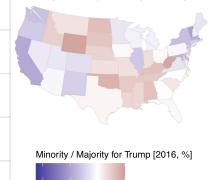


### Farbskalentypen

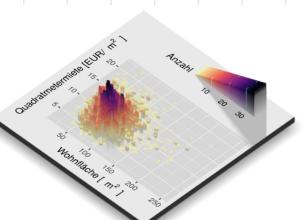
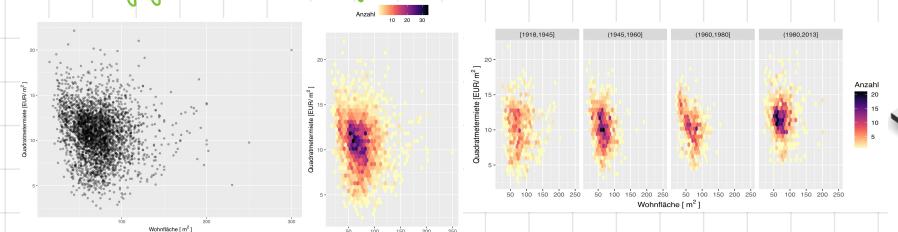
- Qualitativ: (eher) nur für nominales Skalenniveau.
- Sequential: mindestens ordinates Skalenniveau.  $\rightarrow$
- Divergent: mindestens ordinates Skalenniveau mit "neutralen" mittlerem Wert



Beispiel divergente Farbskala



Visualisierung gemeinsamer Verteilungen metrischer Merkmale



# Konvergenz von Zufallsvariablen und Verteilungen

## Punktwise und gleichmäßige Konvergenz

Punktwise Konvergenz:  $\forall x \in \mathbb{R} \forall \varepsilon > 0 \exists N \in \mathbb{N} \forall n > N: |f_n(x) - f(x)| < \varepsilon \quad (\forall x \in \mathbb{R}: \lim_{n \rightarrow \infty} f_n(x) = f(x))$

Gleichmäßige Konvergenz:  $\forall \varepsilon > 0 \exists N \in \mathbb{N} \forall x \in \mathbb{R} \forall n > N: |f_n(x) - f(x)| < \varepsilon \quad (\lim_{n \rightarrow \infty} \sup_{x \in \mathbb{R}} |f_n(x) - f(x)| = 0)$

## Fast sichere Konvergenz

Sei  $(\Omega, \mathcal{F}, \mathbb{P})$  ein Wahrscheinlichkeitsraum und  $X_n: \Omega \rightarrow \mathbb{R}$  eine ZV  $\forall n \in \mathbb{N}$

Dann konvergiert die Folge  $(X_n)_{n \in \mathbb{N}}$  fast sicher gegen  $X: \Omega \rightarrow \mathbb{R}$ , falls

$\mathbb{P}\{\omega \in \Omega \mid \lim_{n \rightarrow \infty} X_n(\omega) = X(\omega)\} = 1$ . Wir schreiben  $X_n \xrightarrow{f.s.} X$ .

Idee: Wir wollen punktwise Konvergenz von  $X_n(\omega) \rightarrow X(\omega)$ ,

aber wollen "unmöglich" Ereignisse ignorieren. Wir sagen  $X_n$  konvergiert fast sicher gegen  $X$ , wenn die punktwise Konvergenz fast-sicher gilt.

## Beispiel

Sei  $X_n \sim U[0,1]$  und  $X_n \sim X_n^n$ . Dann gilt  $X_n \xrightarrow{f.s.} 0$  Funktion die konstant 0 ist.

Beweis: Für alle  $\omega \in \Omega$  mit  $X(\omega) \in [0,1]$  gilt  $\lim_{n \rightarrow \infty} X(\omega)^n = 0$ . Für  $\omega \in \Omega$  mit

$X(\omega) = 1$  gilt  $\lim_{n \rightarrow \infty} X(\omega)^n = 1$ . Also gilt  $\mathbb{P}\{\omega \in \Omega \mid \lim_{n \rightarrow \infty} X(\omega)^n = 0\} = \mathbb{P}\{X(\omega) \in [0,1]\} = \mathbb{P}\{X(\omega) = 1\} = 1$ .

## Satz

Sei  $(X_n)_{n \in \mathbb{N}}$  eine Folge von ZV  $X_i: \Omega \rightarrow \mathbb{R}$  und  $X: \Omega \rightarrow \mathbb{R}$ . Dann gilt

$$X_n \xrightarrow{f.s.} X \Rightarrow X_n \xrightarrow{\mathbb{P}} X$$

## Beispiel für $X_n \xrightarrow{\mathbb{P}} X$ , aber $X_n \not\xrightarrow{f.s.} X$ (anderes Beispiel in Folie 412)

Sei  $\{X_n\}_{n \in \mathbb{N}}$  eine Folge von ZV mit  $\mathbb{P}[X_n = 1] = \frac{1}{n}$  und  $\mathbb{P}[X_n = 0] = 1 - \frac{1}{n}$ . Behauptung:  $X_n \xrightarrow{\mathbb{P}} 0$

Für  $0 < \varepsilon < 1$  gilt  $\lim_{n \rightarrow \infty} \mathbb{P}[|X_n - 0| \geq \varepsilon] = \lim_{n \rightarrow \infty} \mathbb{P}[|X_n| \geq \varepsilon] = \lim_{n \rightarrow \infty} \frac{1}{n} = 0$ . Für  $\varepsilon > 1$  ist es trivial. Also gilt  $X_n \xrightarrow{\mathbb{P}} 0$ .

Behauptung:  $X_n \not\xrightarrow{f.s.} 0$ .  $\sum_{n=1}^{\infty} \mathbb{P}[X_n = 1] = \infty$  (harmonische Reihe). D.h. das Ereignis  $X_n = 1$ . Laut (Borel-Cantelli) Lemma

gilt für Folgen von unabhängigen Ereignissen, deren Wahrscheinlichkeit sich zu  $\infty$  summiert, dass das Ereignis unendlich oft eintritt.

Also gibt es kein  $N \in \mathbb{N}$ , ab dem  $\forall n > N$  gilt  $X_n = 0$ . Somit ist  $\mathbb{P}\{\omega \in \Omega \mid \lim_{n \rightarrow \infty} X_n(\omega) = 0\} = 0 \neq 1$ . Also  $X_n \not\xrightarrow{f.s.} 0$ .

## Konvergenz im Moment

Sei  $(\Omega, \mathcal{F}, \mathbb{P})$  ein Wahrscheinlichkeitsraum und  $X_n: \Omega \rightarrow \mathbb{R}$  eine ZV  $\forall n \in \mathbb{N}$

Dann konvergiert die Folge  $(X_n)_{n \in \mathbb{N}}$  im  $r$ -ten Moment ( $r \in \mathbb{N}$ ) gegen  $X: \Omega \rightarrow \mathbb{R}$ , falls  $\mathbb{E}[|X_n|^r] < \infty \forall n \in \mathbb{N}$  und  $\lim_{n \rightarrow \infty} \mathbb{E}[|X_n - X|^r] = 0$ . Wir schreiben  $X_n \xrightarrow{r} X$ .

## Beispiel

Sei  $r > s \geq 1$  und  $\mathbb{P}[X_n = n] = n^{-\frac{1}{2}(r+s)}$  und  $\mathbb{P}[X_n = 0] = 1 - n^{-\frac{1}{2}(r+s)}$

$\mathbb{E}[|X_n|^s] = n^s \cdot n^{-\frac{1}{2}(r+s)} = n^{\frac{1}{2}(s-r)} \xrightarrow{n \rightarrow \infty} 0$ . Also  $X_n \xrightarrow{s} 0$ .

## Konvergenz in Verteilung

Sei  $(X_i)_{i \in \mathbb{N}}$  eine Folge von ZVen mit Verteilungsfkt.  $F_i$ .

Dann konvergiert  $(X_i)_{i \in \mathbb{N}}$  in Verteilung gegen  $X: \Omega \rightarrow \mathbb{R}$

mit Verteilungsfkt.  $F$ , wenn  $\mathbb{P}(X_{n \rightarrow \infty} = x) = \mathbb{P}(X = x)$

$\forall x \in \mathbb{R} \exists i \in \mathbb{N}$ :  $\lim_{i \rightarrow \infty} F_i(x) = F(x)$ . Wir schreiben  $X_i \xrightarrow{D} X$ .

! Gleiche Definition für Zufallsrektoren  $(X_i)_{i \in \mathbb{N}}$ .

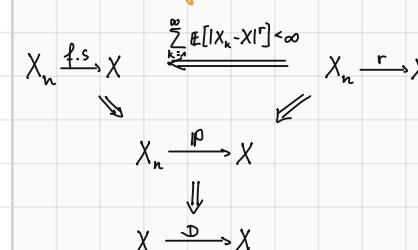
## Satz von Slutsky

Seien  $X_n \xrightarrow{D} X$ ,  $A_n \xrightarrow{\mathbb{P}} a$ ,  $B_n \xrightarrow{\mathbb{P}} b$ , dann gilt  $A_n + B_n X_n \xrightarrow{D} a + bX$

## Satz

Sei  $(X_n)_{n \in \mathbb{N}} \sim B(n, p_n)$  und  $(p_n)_{n \in \mathbb{N}}$  eine Folge mit  $\lim_{n \rightarrow \infty} n \cdot p_n = \lambda > 0$ , dann gilt  $X_n \xrightarrow{D} Po(\lambda)$

## Zusammenhang



# Gesetz der großen Zahlen und zentraler Grenzwertsatz

## i.i.d.-Modell

Sei  $(X_i)_{i \in \mathbb{N}}$  eine Folge von ZVn. Wir nennen die  $X_i$  der Folge i.i.d. (independent identically distributed), wenn sie (i) alle unabhängig voneinander sind und (ii) die gleiche Verteilung besitzen.

## Idee

Sei  $(X_i)_{i \in \mathbb{N}}$  eine Folge von Zufallsvariablen auf einem Wahrscheinlichkeitsraum  $(\Omega, \mathcal{F}, P)$ .

Wir betrachten die Summen  $S_n = X_1 + \dots + X_n$  und interessieren uns für das Verhalten von  $S_n$  für  $n \rightarrow \infty$ .

Die Gesetze der grossen Zahlen beschreiben die Konvergenz von  $\frac{1}{n} S_n$  für  $n \rightarrow \infty$ , während der zentrale GLS eine Angabe über die asymptotische Form der Verteilung von  $S_n$  macht.

## Schwaches Gesetz der großen Zahlen

Sei  $(X_i)_{i \in \mathbb{N}}$  eine Folge von ZVn mit  $E[X_i] = \mu \quad \forall i \in \mathbb{N}$ .

Wir sagen, dass das schwache Gesetz der grossen Zahlen gilt, wenn  $\bar{X}_n := \frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{P} \mu$ . Also  $P[\lim_{n \rightarrow \infty} \bar{X}_n = \mu] = 1$ .

## Satz

heißt: Erwartungswert und Varianz existieren.

Wenn die  $X_i$  i.i.d. sind, mit  $E[X_i^2] < \infty \quad \forall i \in \mathbb{N}$ , so gilt das schwache Gesetz der großen Zahlen.

Beweis: Wegen  $(X_n)_{n \in \mathbb{N}}$  i.i.d. und  $E[X_n] = \mu$  und  $\text{Var}[X_n] = \sigma^2 \quad \forall n \in \mathbb{N}$  folgt:  $E[\bar{X}_n] = \mu$  und  $\text{Var}[\bar{X}_n] = \frac{1}{n} \text{Var}[X_n]$ .  $\mathbb{P}[|\bar{X}_n - \mu| > \varepsilon] \leq \frac{\text{Var}(\bar{X}_n)}{\varepsilon^2} = \frac{\text{Var}(X_n)}{n \cdot \varepsilon^2}$ . Für  $n \rightarrow \infty$  folgt der Satz.

Anmerkung:  $X_n$  i.i.d. ist nicht zwingend nötig. Es reicht gleich-verteilt und unkorreliert (statt unabhängig) und das der Erwartungswert  $E[X_i]$  existiert.

## Starkes Gesetz der großen Zahlen

Sei  $(X_i)_{i \in \mathbb{N}}$  eine Folge von ZVn mit  $E[X_i] = \mu \quad \forall i \in \mathbb{N}$ .

Wir sagen, dass das starke Gesetz der grossen Zahlen gilt, wenn  $\bar{X}_n := \frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{P.S.} \mu$ . Also  $P[\lim_{n \rightarrow \infty} \bar{X}_n = \mu] = 1$ .

## Satz

heißt: Erwartungswert existiert und ist endlich.

Wenn die  $X_i$  i.i.d. sind, mit  $E[|X_i|] < \infty \quad \forall i \in \mathbb{N}$ , so gilt das starke Gesetz der großen Zahlen.

Intuition: Schwaches Gesetz besagt, dass endliche Stichproben für grosses  $n$ , bis auf ein paar unglückliche Stichproben, "ausgeglichen" sind. Starkes Gesetz besagt, dass unendliche Stichproben fast immer "ausgeglichen" sind und das die Menge der "unausgeglichenen" Stichproben Wahrscheinlichkeit 0 hat.

## Zentraler Grenzwertsatz

Seien  $(X_n)_{n \in \mathbb{N}}$  i.i.d. ZVn mit  $E[X_n] = \mu$  und  $\text{Var}[X_n] = \sigma^2 < \infty$ . Sei  $S_n = \sum_{i=1}^n X_i$ . Dann gilt:

$$1) \lim_{n \rightarrow \infty} P\left[\frac{S_n - n\mu}{\sqrt{n}\sigma} \leq x\right] = N(0, 1) \quad \text{bzw. } \frac{S_n - n\mu}{\sqrt{n}\sigma} \xrightarrow{D} N(0, 1) \quad \text{bzw. } S_n \sim N(n\mu, n\sigma^2)$$

$$2) \lim_{n \rightarrow \infty} P\left[\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \leq x\right] = N(0, 1) \quad \text{bzw. } \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{D} N(0, 1) \quad \text{bzw. } \bar{X}_n \sim N(\mu, \frac{\sigma^2}{n})$$

## Zentraler Grenzwertsatz mehrdimensional

Seien  $(X_n)_{n \in \mathbb{N}}$  i.i.d. k-dim. ZV mit  $E[X_n X_n^T] < \infty$ . Sei  $E[X_n] = \mu$  und  $V[X_n] = \Sigma$ , dann gilt:

$$\lim_{n \rightarrow \infty} P\left[\frac{\sum_{j=1}^n X_j - n\mu}{\sqrt{n}} \leq x\right] = M_k(0, \Sigma) \quad \text{bzw. } \frac{1}{\sqrt{n}} \left( \sum_{j=1}^n X_j - n\mu \right) \xrightarrow{D} M_k(0, \Sigma)$$

## Schlussfolgerung aus 'thinking fast and slow'

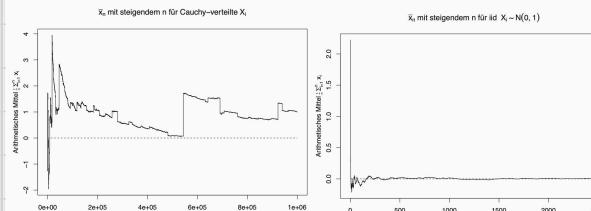
- Große Stichproben liefern präzisere Ergebnisse als kleine Stichproben.
- Kleine Stichproben führen häufiger zu extremen Ergebnissen als grosse Stichproben.

## Beispiel für den Fall, dass das Gesetz d.g. Zahlen nicht gilt

Sei  $(X_i)_{i \in \mathbb{N}}$  i.i.d. mit  $X_i \sim \mathcal{C}$ . Dann kann man zeigen, dass auch

$\bar{X}_n \sim \mathcal{C}$ . Somit ist  $E(\bar{X}_n)$  nicht existent.  $\bar{X}_n$  streut also stark  $\forall n \in \mathbb{N}$ .

Somit ist das schwache Gesetz der grossen Zahlen nicht erfüllt.



## Satz von Glivenko-Cantelli / Hauptsatz der Statistik

Seien  $X_1, \dots, X_n$  i.i.d. ZVn mit  $X_i \sim F$ . Wir definieren die empirische Verteilungsfkt. als

$$\hat{F}(x) := \frac{1}{n} \sum_{i=1}^n I_{(-\infty, x]}(X_i). \quad \text{Es gilt:}$$

$$(i) \quad \hat{F} \xrightarrow{P.S.} F \quad \forall x \in \mathbb{R}$$

$$(ii) \quad \sqrt{n}(\hat{F}_n(x) - F(x)) \xrightarrow{D} N(0, F(x) \cdot (1-F(x))) \quad \forall x \in \mathbb{R}$$

$$(iii) \quad \sup_{x \in \mathbb{R}} |\hat{F}_n(x) - F(x)| \xrightarrow{P.S.} 0$$

# Zufallsvektoren

## Zufallsvektor

Ist  $(\Omega, \mathcal{F}, P)$  ein Wahrscheinlichkeitsraum und  $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n))$  Maßraum, so heißt eine  $\mathcal{F}$ -messbare Abb.  $X: \Omega \rightarrow \mathbb{R}^n$  n-dimensionaler Zufallsvektor.

## Produktmaß

Das Produktmaß  $\left(\bigotimes_{i=1}^n \mu_i\right)$  ist definiert durch  $\left(\bigotimes_{i=1}^n \mu_i\right)\left(\bigotimes_{i=1}^n A_i\right) := \prod_{i=1}^n \mu_i(A_i) \quad \forall A_i \in \mathcal{F}_i, i \in \{1, \dots, n\}$

## Mehrdimensionale Verteilungsfunktion

### n-dim. Verteilungsfunktion

Sei  $(\Omega, \mathcal{F}, P)$  ein Wahrscheinlichkeitsraum. Sei  $X: \Omega \rightarrow \mathbb{R}^n$  eine n-dim. reelle ZV,  $\underline{X} = (X_1, \dots, X_n)$ .

Dann heißt  $F_X: \mathbb{R}^n \rightarrow [0, 1]$ ,  $x = (x_1, \dots, x_n) \mapsto P[X \leq x] = P[X_1 \leq x_1, \dots, X_n \leq x_n] = P[\{\omega \in \Omega | X_i(\omega) \leq x_i, \forall i\}]$

## Satz

Sei  $X: \Omega \rightarrow \mathbb{R}^n$  eine n-dim. ZV und  $g: \mathbb{R}^n \rightarrow \mathbb{R}^k$   $\mathcal{B}^n \times \mathcal{B}^k$ -messbar.

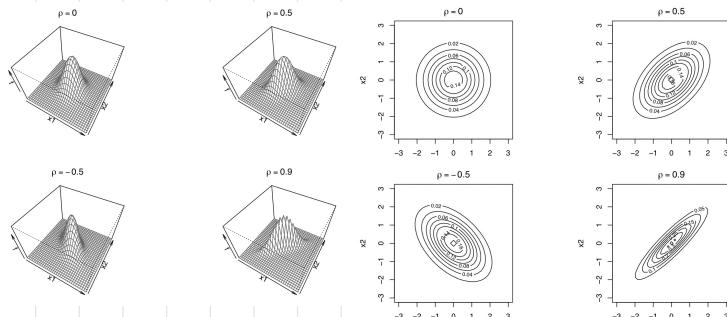
Dann ist  $g \circ X: \Omega \rightarrow \mathbb{R}^k$ ,  $\omega \mapsto g(X(\omega))$  eine k-dimensionale reelle ZV mit Verteilung  $P_{g(X)}[A] = P[g(X) \in A] = P[\{\omega \in \Omega | g(X(\omega)) \in A\}]$

## 2-dimensionale Normalverteilung

Sei  $X: \Omega \rightarrow \mathbb{R}^2$  eine ZV mit Dichte

$$f_{\underline{X}}(x_1, x_2) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \cdot \exp\left(-\frac{1}{2(1-\rho^2)}\left(\frac{(x_1-\mu_1)^2}{\sigma_1^2} + \frac{(x_2-\mu_2)^2}{\sigma_2^2} - \frac{2\rho(x_1-\mu_1)(x_2-\mu_2)}{\sigma_1\sigma_2}\right)\right)$$

Dann ist  $\underline{X} \sim \mathcal{N}_2\left(\begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix}\right)$



## n-dim. σ-Algebra

Ist  $\Omega = \bigotimes_{i=1}^n \Omega_i$  und  $\mathcal{F}_i$  σ-Algebra von  $\Omega_i$  für alle  $i$ , dann lässt sich eine σ-Algebra für  $\Omega$  definieren als:  $\bigotimes_{i=1}^n \mathcal{F}_i := \sigma\left(\left\{\bigotimes_{i=1}^n A_i \mid A_i \in \mathcal{F}_i, i \in \{1, \dots, n\}\right\}\right)$

## Borelsche σ-Algebra im n-dim.

Siehe Def. Borelsche σ-Algebra.  $\mathcal{O}^n = \bigotimes_{i=1}^n \mathcal{O}_i$

## Produktmaßraum

Seien  $(\Omega_i, \mathcal{F}_i, \mu_i)$ ,  $i \in \{1, \dots, n\}$  Maßräume. Ihr Produktmaßraum ist der Maßraum

$$\left(\bigotimes_{i=1}^n \Omega_i, \bigotimes_{i=1}^n \mathcal{F}_i, \bigotimes_{i=1}^n \mu_i\right)$$

## Satz von Fubini

Seien  $(\Omega_1, \mathcal{F}_1, \mu_1)$  und  $(\Omega_2, \mathcal{F}_2, \nu_2)$  zwei Maßräume mit σ-endlichen Maßen  $\mu_1$  und  $\nu_2$ .

Ist  $f: \Omega_1 \times \Omega_2 \rightarrow \mathbb{R}$  eine nicht-negative  $(\mathcal{F}_1 \otimes \mathcal{F}_2)$ -B-messbare Funktion bzw. eine  $(\mu_1 \otimes \nu_2)$ -integrale Funktion, so gilt

$$\int f d(\mu_1 \otimes \nu_2) = \int \int f(\omega_1, \omega_2) d\mu_1 d\nu_2 = \int \int f(\omega_1, \omega_2) d\nu_2 d\mu_1$$

## Randverteilung

Ist  $g: \mathbb{R}^n \rightarrow \mathbb{R}$  mit  $g(x) = x_j$  für ein festes  $j \in \{1, \dots, n\}$ , so gilt  $g(X) = X_j$ ,  $P_{X_j}[A] = P_X[\{x \in \mathbb{R}^n | x_j \in A\}] = P[X_j \in A]$  für  $A \in \mathcal{B}$ .

$P_{X_j}$  heißt Randverteilung oder marginale Verteilung von  $X_j$ .

## Satz

Besitzt  $X$  die Dichte  $f$ , so hat  $X_j$  die marginale Dichte bzw. Randdichte  $f_{X_j}: \mathbb{R} \rightarrow \mathbb{R}$

$$f_{X_j}(y) = \int \dots \int f(x_1, \dots, x_{j-1}, y, x_{j+1}, \dots, x_n) dx_1 \dots dx_{j-1} dx_{j+1} \dots dx_n$$

## Beispiel

Für die 2-dim. Norm-verteilte ZV  $X$  gilt:

$$f_{X_2}(x_2) = \int_{\mathbb{R}} f(x_1, x_2) dx_1 = \dots = \frac{1}{\sqrt{2\pi\sigma_2^2}} \cdot \exp\left(-\frac{1}{2}(x_2 - \mu_2)^2\right). \text{ Also ist } X_2 \sim \mathcal{N}(\mu_2, \sigma_2^2). \text{ Genauso gilt } X_1 \sim \mathcal{N}(\mu_1, \sigma_1^2)$$

## Multinomialverteilung

Urnenmodell mit  $k$  Farben und  $n$  gezogenen Kugeln ohne Zurücklegen. Die ZV  $X = (X_1, \dots, X_k)$  beschreibt die gezogenen Farben, wobei  $X_i$  die Anzahl Kugeln mit Farbe  $i$  ist.

Sei  $k, n \in \mathbb{N}$  und  $p_1, \dots, p_k \in [0, 1]$  mit  $\sum p_i = 1$ . Die Verteilung mit der Zähldichte  $f(n_1, \dots, n_k) = \frac{n_1 + \dots + n_k}{n!} \cdot p_1^{n_1} \dots p_k^{n_k}$  heißt Multinomialverteilung.

## Beispiel

$$f(n_1, \dots, n_k) = \frac{n_1 + \dots + n_k}{n!} \cdot p_1^{n_1} \dots p_k^{n_k}$$

$$f_{X_1}(n_1) = \sum_{n_2 + \dots + n_k = n-n_1} f(n_1, \dots, n_k) = \dots = \frac{n!}{n_1!(n-n_1)!} \cdot p_1^{n_1} \cdot \left(\sum_{i=2}^k p_i\right)^{n-n_1}$$

# Unabhängigkeit

## Satz

Sei  $\underline{X} = (X_1, \dots, X_n)$  eine reelle  $n$ -dimensionale ZV. Dann gilt  
 $X_1, \dots, X_n$  stochastisch unabhängig  $\Leftrightarrow \forall \underline{x} \in \mathbb{R}^n: P[X \leq \underline{x}] = \prod_{i=1}^n P[X_i \leq x_i]$

## Satz

Sind  $X_1, \dots, X_n$  reelle ZV mit Dichten  $f_{X_1}, \dots, f_{X_n}$ .  
 $X_1, \dots, X_n$  sind unabhängig  $\Leftrightarrow$  Für  $X = (X_1, \dots, X_n)$  gilt  $\forall \underline{x}: f_X(\underline{x}) = \prod_{i=1}^n f_{X_i}(x_i)$

## Satz

Seien  $X_1: \Omega \rightarrow \mathbb{R}^{n_1}$ ,  $X_2: \Omega \rightarrow \mathbb{R}^{n_2}$  zwei stochastisch unabhängige ZV und seien  $h_1: \mathbb{R}^{n_1} \rightarrow \mathbb{R}^{m_1}$  und  $h_2: \mathbb{R}^{n_2} \rightarrow \mathbb{R}^{m_2}$  messbare Funktionen.  
Dann sind  $Y_1 := h_1 \circ X_1$  und  $Y_2 := h_2 \circ X_2$  stoch. unabhängig.

## Transformationssatz

### Transformationssatz für lineare Transformationen

Sei  $g: \mathbb{R}^n \rightarrow \mathbb{R}^n$  invertierbar und linear, d.h.  $g(\underline{x}) = B\underline{x} + \underline{m}$  mit  $\det(B) \neq 0$ . Sei  $\underline{y} = g(\underline{X})$ .

Wenn  $f_{\underline{X}}$  absolutstetig ist, so ist auch  $f_{\underline{y}}$  absolutstetig und  $f_{\underline{y}}(\underline{y}) = \frac{1}{|\det(B)|} \cdot f_{\underline{X}}(B^{-1}(\underline{y} - \underline{m}))$

### Beispiel Faltung

Sei  $\bar{X} = (X_1, X_2)$  eine zweidimensionale absolutstetige ZV. Setze  $\bar{Y} = g(\bar{X}) = (X_1, \bar{X}_1 + \bar{X}_2)$ .

Dann ist  $B = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$  bzw.  $B^{-1} = \begin{pmatrix} 1 & 0 \\ -1 & 1 \end{pmatrix}$ .  $\Rightarrow f_{\bar{Y}}(x_1, y) = \frac{1}{1} \cdot f_{\bar{X}}(B^{-1}(y)) = f_{\bar{X}}(x_1, y - x_1)$

Für  $\bar{z} = \bar{X}_1 + \bar{X}_2$  gilt also:  $f_{\bar{Z}}(\bar{z}) = \int_{\mathbb{R}^2} f_{\bar{Y}}(x_1, y) dx_1 dy = \int_{\mathbb{R}^2} f_{\bar{X}}(x_1, y - x_1) dx_1 dy$ .

Für unabhängige  $X_1, X_2$  gilt  $f_{\bar{X}}(x_1, x_2) = f_{X_1}(x_1) \cdot f_{X_2}(x_2)$ .  $\Rightarrow f_{\bar{Z}}(\bar{z}) = \int_{\mathbb{R}^2} f_{X_1}(x_1) \cdot f_{X_2}(y - x_1) dx_1 dy = f_{X_1} * f_{X_2}$

Faltung beschreibt wie die Form von einer Funktion durch eine andere Funktion modifiziert wird. Anschaulich bedeutet  $f * g$ , dass jeder Wert von  $f$  durch das mit  $g$  gewichtete Mittel der ihn umgebenden Werte ersetzt wird.

### Beispiel

Seien  $X_1, X_2 \sim U(\pi)$  und unabhängig. Wir betrachten  $\bar{Y} = X_1 + X_2$ .  $T_{\bar{Y}} = \mathbb{N}_0 \cup \{\infty\}$

$$P(Y=n) = P(X_1 + X_2 = n) = \sum_{k=1}^{n-1} P(X_1 = k) P(X_2 = n-k) = \sum_{k=1}^{n-1} (\frac{1}{\pi})^k \cdot \pi \cdot (\frac{1-\pi}{\pi})^{n-k-1} \cdot \pi = \sum_{k=1}^{n-1} (\frac{1-\pi}{\pi})^{n-2} \cdot \pi^2 = (\frac{1-\pi}{\pi})^{n-2} \cdot \pi^2$$

### Beispiel

Seien  $X_1 \sim P(\lambda_1)$ ,  $X_2 \sim P(\lambda_2)$  und unabhängig. Wir betrachten  $\bar{Y} = X_1 + X_2$ .

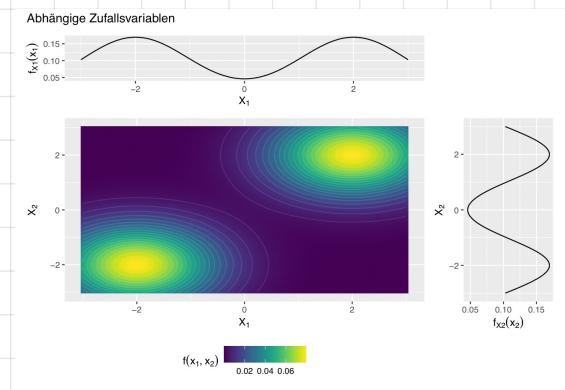
$$P(Y=n) = P(X_1 + X_2 = n) = \sum_{k=0}^n P(X_1 = k) P(X_2 = n-k) = \underbrace{\left( \sum_{k=0}^n (k) \cdot \lambda_1^k \cdot \lambda_2^{n-k} \right)}_{= (\lambda_1 + \lambda_2)^n} \cdot e^{-(\lambda_1 + \lambda_2)}$$

### Allgemeiner Transformationssatz

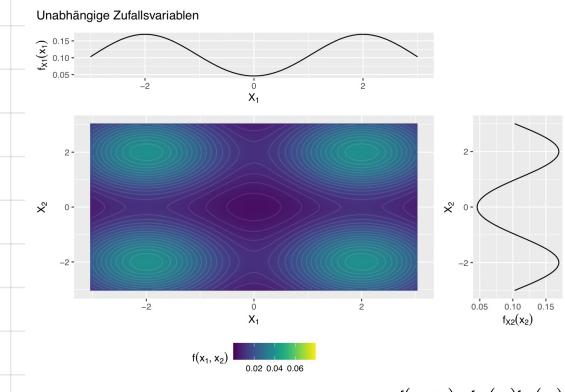
Sei  $\underline{X}: \Omega \rightarrow \mathbb{R}^n$  eine ZV mit stetiger Dichte  $f_{\underline{X}}$ . Sei  $g: \mathbb{R}^n \rightarrow \mathbb{R}^n$  messbar. Sei  $G_m \in \mathcal{B}^n$  mit  $\bigcup_{m \in M} G_m = \mathbb{R}^n$ , so dass  $g_m := g|_{G_m}$  bijektiv und stetig diff. bar. Sei  $J_{g_m}(y) = \begin{pmatrix} \frac{\partial g_m^{-1}(y)}{\partial y_j} \end{pmatrix}_{\substack{i=1, \dots, n \\ j=1, \dots, n}}$  die Jacobimatrix von  $g_m^{-1}$ . Dann gilt:

$$f_{\underline{g}(\underline{x})}(\underline{x}) = \sum_{m \in M} V_m(\underline{x}), \quad V_m(\underline{x}) = \begin{cases} f_{\underline{X}}(g_m^{-1}(\underline{x})) \cdot \det(J_{g_m^{-1}}(\underline{x})) & , \text{ falls } g_m^{-1}(\underline{x}) \in G_m \\ 0 & , \text{ sonst} \end{cases}$$

Partition von  $\mathbb{R}^n$ .



$$f(x_1, x_2) = f_{X_1}(x_1)f_{X_2}(x_2)$$



$$f(x_1, x_2) = f_{X_1}(x_1)f_{X_2}(x_2)$$

## Bedingte Verteilungs- & Dichtefunktion

Die bedingte Verteilungsfunktion  $F_{X|Y}(x|y)$  und die bedingte Wahrscheinlichkeits- bzw.

Dichtefunktion  $f_{X|Y}(x|y)$ , gegeben  $Y=y$  mit  $y \in T_Y$ , sind definiert als:

$$F_{X|Y} = P(X \leq x | Y=y) = \begin{cases} \frac{P(X \leq x, Y=y)}{P(Y=y)}, & X, Y \text{ diskret} \\ \int_{-\infty}^x f_{X|Y}(u|y) du, & X, Y \text{ stetig} \end{cases}$$

$$f_{X|Y}(x|y) = \begin{cases} \frac{P(X=x, Y=y)}{P(Y=y)}, & X, Y \text{ diskret} \\ \frac{f_{X,Y}(x,y)}{f_Y(y)}, & X, Y \text{ stetig} \end{cases}$$

## Beispiel

Sei  $X \sim \text{Be}(\alpha, \beta)$  und  $Y|X = \mathcal{B}(n, \pi=X)$ .

Dann gilt  $f(x,y) = \frac{1}{B(\alpha, \beta)} \cdot \binom{n}{y} \cdot x^y \alpha^{-1} \cdot (1-x)^{n-y} \beta^{-1}$

$\Rightarrow X|Y \sim \text{Be}(\alpha+y, \beta+n-y)$

$f_Y(y) = \binom{n}{y} \cdot \frac{B(\alpha+y, \beta+n-y)}{B(\alpha, \beta)}$  für  $y=0, \dots, n$

$Y \sim \mathcal{BB}(n, \alpha, \beta)$  Beta-Binomialverteilung

## Beta-Binomialverteilung

Die Anzahl Erfolge in  $n$  unabhängigen Bernoulli-Experimenten mit Beta-verteilten Erfolgswahrscheinlichkeiten ist Beta-Binomialverteilt mit  $X \sim \text{BeB}(n, \alpha, \beta)$

und  $n \in \mathbb{N}$ ,  $\alpha, \beta \in \mathbb{R}^+$ . Es gilt

$$P_{n,\alpha,\beta}(X=x) = \binom{n}{x} \cdot \frac{B(\alpha+x, \beta+n-x)}{B(\alpha, \beta)}$$

wobei  $B$  die Betafunktion ist.

## Bedingte Momente

$$E(X|Z=z) = \begin{cases} \sum_{x \in T_X} x \cdot P(X=x|Z=z), & X \text{ diskret} \\ \int_{\mathbb{R}} x \cdot f_{X|Z}(x|Z=z) dx, & X \text{ stetig} \end{cases}$$

?  $E(X|Z)$  ist ein ZV  
 $E(X|Z=z)$  ist ein Zahlenwert

$$\text{Var}(X|Z=z) = E(X - E(X|Z=z)|Z=z) = \begin{cases} \sum_{x \in T_X} (x - E(X|Z=z))^2 \cdot P(X=x|Z=z), & X \text{ diskret} \\ \int_{\mathbb{R}} (x - E(X|Z=z))^2 f_{X|Z}(x|Z=z) dx, & X \text{ stetig} \end{cases}$$

## Satz vom iterierten Erwartungswert

Für beliebige ZV  $X, Y$  und Funktion  $f$  gilt:

$$E[E(f(X)|Z)] = E(f(X))$$

## Satz von der totalen Varianz

Für beliebige ZV  $X, Y$  gilt:

$$\text{Var}(X) = E[\text{Var}(X|Z)] + \text{Var}[E(X|Z)]$$

Zerwartete bedingte Varianz      Varianz des bedingten Erwartungswertes

## Satz

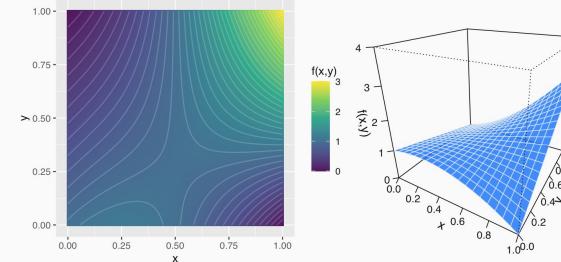
$$f_{X,Y}(x,y) = f_{X|Y}(x|y) \cdot f_Y(y) = f_{Y|X}(x|y) \cdot f_X(x)$$

$X, Y$  sind unabhängig  $\Leftrightarrow f_{X,Y}(x,y) = f_X(x) \cdot f_Y(y) \quad \forall x, y \in X, Y \Leftrightarrow f_{Y|X}(x|y) = f_Y(y) \quad \forall x, y \in X, Y$

## Beispiel

Sei  $(X, Y) \in [0, 1] \times [0, 1]$  ein stetiger Zufallsvektor mit gemeinsamer Dichte

$$f_{X,Y}(x,y) = (1 + x - y - 2x^2 + 4x^2y) \cdot I(x \in [0, 1]) \cdot I(y \in [0, 1]):$$



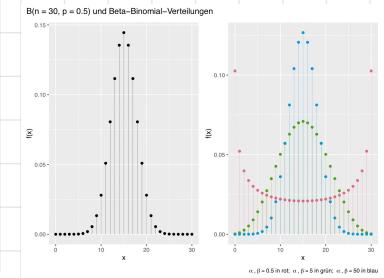
$$f_X(x) = \int_0^1 f_{X,Y}(x,y) dy = \int_0^1 1 + x - y - 2x^2 + 4x^2y dy = 1 + x - 2x^2 + (4x^2 - 1) \cdot \int_0^1 y dy = \frac{1}{2} + x$$

$$f_{Y|X}(x,y) = \frac{f_{X,Y}(x,y)}{f_X(x)} = \frac{1 + x - y - 2x^2 + 4x^2y}{\frac{1}{2} + x} = 2 \cdot (2xy - x - y + 1)$$

## Beispiel

$$\begin{aligned} \text{Seien } X, Y \text{ zwei unabhängige ZV. } X \sim \mathcal{P}(\lambda_1), \\ Y \sim \mathcal{P}(\lambda_2), \quad Z = X + Y \sim \mathcal{P}(\lambda_1 + \lambda_2) \\ X|Z = z \sim \mathcal{B}(z, \pi = \frac{\lambda_1}{\lambda_1 + \lambda_2}) \end{aligned}$$

$$\begin{aligned} P(X=x|Z=z) &= \frac{P(X=x, Y=z-x)}{P(Z=z)} \\ &= \frac{P(X=x) \cdot P(Y=z-x)}{P(Z=z)} \\ &= \binom{z}{x} \cdot \left(\frac{\lambda_1}{\lambda_1 + \lambda_2}\right)^x \cdot \left(1 - \frac{\lambda_1}{\lambda_1 + \lambda_2}\right)^{z-x} \end{aligned}$$



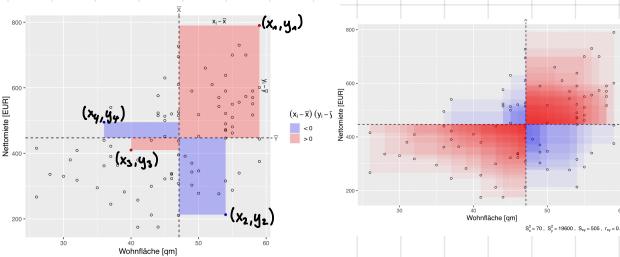
# Zusammenhangsmaße für metrische Merkmale

## Kovarianz (Emperie)

Die Kovarianz ist eine Kennzahl für Stärke & Richtung des linearen Zusammenhangs zweier metrischer Merkmale.

Für die Daten  $(x_i, y_i)_{i=1, \dots, n}$  ist die Kovarianz definiert als:

$$S_{xy} = \frac{1}{n-1} \cdot \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$



## Bravais-Pearson-Korrelationskoeffizient

$X, Y$  (mindestens) ordinal.

Idee: Berechne den Bravais-Pearson-Korrelationskoeffizienten für die Ränge statt für die Merkmalswerte.

$$r_{xy}^{SP} = \frac{\sum_{i=1}^n (R(x_i) - \bar{R}_x)(R(y_i) - \bar{R}_y)}{\sqrt{\sum_{i=1}^n (R(x_i) - \bar{R}_x)^2 \cdot \sum_{i=1}^n (R(y_i) - \bar{R}_y)^2}} = r_{R(X)R(Y)}$$

$r_{xy}^{SP} > 0$ : gleichsinriger monotoner Zusammenhang

$r_{xy}^{SP} < 0$ : gegensinriger monotoner Zusammenhang

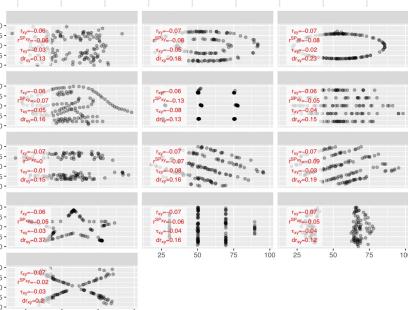
$r_{xy}^{SP} = 0$ : kein monotoner Zusammenhang (unkorreliert)

Wenn alle  $R(x_i), R(y_i)$  voneinander verschieden sind,

so kann man  $r_{xy}^{SP}$  verkürzt berechnen durch

$$r_{xy}^{SP} = 1 - \frac{6 \cdot \sum_{i=1}^n d_i^2}{(n^2 - 1) \cdot n}, \quad d_i := R(x_i) - R(y_i)$$

Seien  $(x_{(1)}, y_{(1)})$  die nach Grösse sortierten Daten (aufsteigend), dann ist  $R(x_{(1)}) = i$ , wenn  $x_{(i)}$  unique ist. Für mehrere gleiche Werte  $x_{(i)} = x_{(i+1)} = \dots$  nimmt man den Durchschnitt der Indizes als Rang.



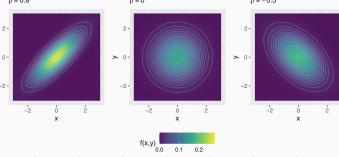
## Beispiel multivariater Zusammenhänge

## Beispiel - Bivariate Standardnormalverteilung

Die Bivariate Standardnormalverteilung mit Parameter  $\rho$  ( $|\rho| < 1$ ) hat Träger  $T = \mathbb{R} \times \mathbb{R}$  und Dichtefunktion

$$f(x, y) = \frac{1}{2\pi\sqrt{1-\rho^2}} \exp\left(-\frac{1}{2(1-\rho^2)}(x^2 - 2\rho xy + y^2)\right)$$

Die Randverteilungen von  $X, Y$  sind für jeden  $\rho$  Standardnormalverteilt.  $\rho(X, Y) = \rho$ . Wenn  $\rho = 0$ , so folgt in diesem Spezialfall Unabhängigkeit von  $X, Y$ .



## Paarvergleichsmaße: Kendall's Tau

Betrachte Paare von Beobachtungen  $(x_i, y_i), (x_j, y_j)$ . Ein Paar heißt konkordant falls  $(x_i) < (x_j)$  und  $(y_i) < (y_j)$  oder  $(x_i) > (x_j)$  und  $(y_i) > (y_j)$ .

diskordant falls  $x_i < x_j$  und  $y_i > y_j$  oder  $x_i > x_j$  und  $y_i < y_j$

$N_c$  ist die Anzahl konkordanter Paare.  $N_d$  die Anzahl diskordanter Paare.

Kendall's Tau ist definiert als  $\tau_{xy} := \frac{N_c - N_d}{\binom{n}{2}} = 2 \cdot \frac{N_c - N_d}{n \cdot (n-1)}$

Varianten: • Goodman & Kruskal  $\gamma$ -Koeffizient ignoriert Bindungen (Ties).

$$\gamma_{xy} := \frac{N_c - N_d}{N_c + N_d}$$

• Somers D wird typischerweise verwendet, wenn  $Y$  binär ist.  
⇒ Viele Paare mit Bindungen in  $Y$ .

$$D_{xy} := \frac{N_c - N_d}{\text{Anzahl Paare mit ungleichem}}$$

## Distanz-Kovarianz & Distanz-Korrelation

Modernes Zusammenhangsmaß für (fast) beliebige Zusammenhänge (nicht nur monoton/lin.) basierend auf Produkten der normierten Distanzen der Beobachtungen untereinander, nicht nur Distanzen zu Mittelwerten.

$$dS_{xy} := \frac{1}{n^2} \cdot \sum_{i=1}^n \sum_{j=1}^n d_{ij}^x \cdot d_{ij}^y$$

$$d_{ij}^x := d_{ij}^x + \bar{d}^x - \bar{d}_{ij}^x - \bar{d}_i^x, \quad d_{ij}^x := |x_i - x_j|,$$

$$\bar{d}_i^x := \frac{1}{n} \sum_j d_{ij}^x, \quad \bar{d}^x := \frac{1}{n^2} \sum_{i,j} d_{ij}^x$$

$$d_{xy} := \sqrt{\frac{dS_{xy}^2}{1/dS_{xx}^2 + 1/dS_{yy}^2}} \in [0, 1]$$

! Muss nur Stärke und nicht Richtung.  
Lässt sich mit geeigneter Metrik auf fast alles anwenden.

$d_{xy} = 0 \Leftrightarrow X, Y$  unabhängig

## Zusammenhangmaße für dichotome und ordinale/metrische Merkmale

### Beispiel

- > Medizin:  $X$  = Biomarker oder diagnostischer Score  
 $Y$  = krank vs. nicht krank
- > Marketing:  $X$  = Kundeneigenschaften  
 $Y$  = Kaufentscheidung (ja/nein)

### Sensitivität und Spezifität

$Y \in \{0,1\}$  (Zielgröße),  $X$  mindestens ordinalskaliert

$Y=1$  : "positiver" Fall,  $Y=0$  : "negativer" Fall

Sei  $\hat{y}_i$  die Prognose für  $y_i$  auf Basis von  $x_i$ . Es soll gelten

$$\hat{y}_i = 1 \Leftrightarrow x_i \geq c.$$

$y_i = 0$	$y_i = 1$		
Vorhersage $\hat{y}_i = 0$	wahr negativ	falsch negativ	# negative Vorhersagen
Vorhersage $\hat{y}_i = 1$	falsch positiv	wahr positiv	# positive Vorhersagen
	# negative	# positive	

$$\text{Sensitivität: } TPR(c) = f(\hat{y}=1|Y=1) = f(X \geq c|Y=1) = \frac{\# \text{ wahr pos.}}{\# \text{ true pos. rate}}$$

$$\text{Spezifität: } TNR(c) = f(\hat{y}=0|Y=0) = 1 - f(X \geq c|Y=0) = \frac{\# \text{ wahr neg.}}{\# \text{ neg.}}$$

$$\text{False pos. rate: } FPR(c) = f(\hat{y}=1|Y=0) = f(X \geq c|Y=0) = \frac{\# \text{ falsch pos.}}{\# \text{ neg.}}$$

### ROC-Kurve

Die ROC-Kurve zeigt die Zuverlässigkeit der Vorhersagen für alle möglichen Schwellenwerte  $c$  an.

Verbindet die Punkte  $(FPR(c), TPR(c)) \forall c \in [x_{(1)}, x_{(n)}]$

$$\text{Für } c < x_{(1)} \Rightarrow \hat{y}_i = 1 \forall i \Rightarrow (FPR(c), TPR(c)) = (1,1)$$

$$\text{Für } c > x_{(n)} \Rightarrow \hat{y}_i = 0 \forall i \Rightarrow (FPR(c), TPR(c)) = (0,0)$$

### AUC-Maß

Maß zur Bewertung der ROC Kurve.

$$AUC := \frac{N_c + N_E}{2} \quad , \quad N_c := \text{Anzahl konkordanter Paare}$$

$$, \quad N_E := \text{Anzahl Paare mit Bindung in } X \\ = |\{(i,j) : x_i = x_j, y_i > y_j\}|$$

### Positiv/negativ prädikater Wert (ppV, npV)

$$ppV := f(Y=1 | \hat{Y}=1) = \frac{\# \text{ wahr pos.}}{\# \text{ pos. Vorhersagen}}$$

$$npV := f(Y=0 | \hat{Y}=0) = \frac{\# \text{ wahr neg.}}{\# \text{ neg. Vorhersagen}}$$

### Beispiel

NIPT-test für Trisomie 21. Prävalenz 8 in 10000.

NIPT-Sensitivität: 99.2%, NIPT-Spezifität: 99.9%

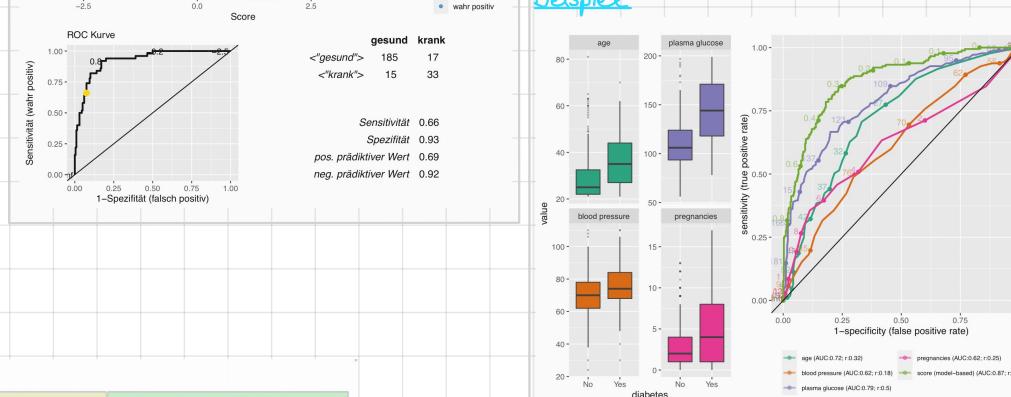
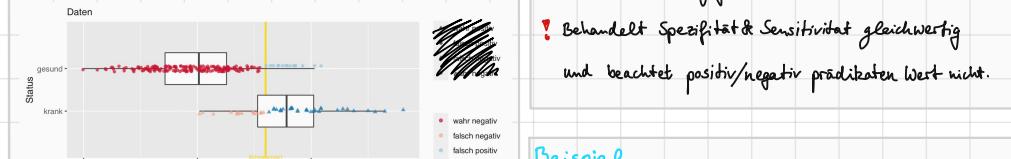
Erwartete Häufigkeiten:

	Kind krank	Kind gesund	
NIPT: "Kind krank"	794	999	1793
NIPT: "Kind gesund"	6	998 201	998207
	800	999 200	1 000 000

$$npV = 0.99894, ppV = 0.443$$

⇒ negative NIPT-Diagnosen sind nahezu sicher korrekt, aber von den positiven sind nur 44% korrekt.

### Beispiel

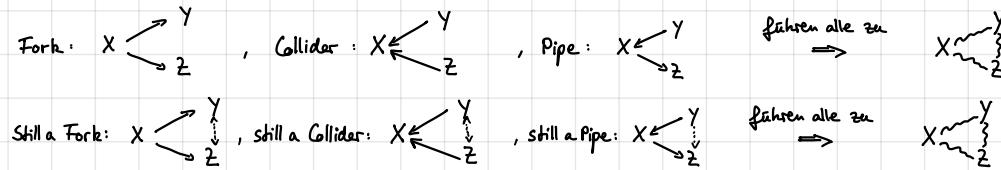


True condition				
Total population	Condition positive	Condition negative	Prevalence = $\frac{\sum \text{Condition positive}}{\sum \text{Total population}}$	Accuracy (ACC) = $\frac{\sum \text{True positive} + \sum \text{True negative}}{\sum \text{Total population}}$
Predicted condition positive	<b>True positive</b>	<b>False positive, Type I error</b>	Positive predictive value (PPV), Precision = $\frac{\sum \text{True positive}}{\sum \text{Predicted condition positive}}$	False discovery rate (FDR) = $\frac{\sum \text{False positive}}{\sum \text{Predicted condition positive}}$
Predicted condition negative	<b>False negative, Type II error</b>	<b>True negative</b>	False omission rate (FOR) = $\frac{\sum \text{False negative}}{\sum \text{Predicted condition negative}}$	Negative predictive value (NPV) = $\frac{\sum \text{True negative}}{\sum \text{Predicted condition negative}}$
	True positive rate (TPR), Recall, Sensitivity, probability of detection, Power = $\frac{\sum \text{True positive}}{\sum \text{Condition positive}}$	False positive rate (FPR), Fall-out, probability of false alarm = $\frac{\sum \text{False positive}}{\sum \text{Condition negative}}$	Positive likelihood ratio (LR+) = $\frac{\text{TPR}}{\text{FPR}}$	Diagnostic odds ratio (DOR) = $\frac{\text{LR+}}{\text{LR-}}$
	False negative rate (FNR), Miss rate = $\frac{\sum \text{False negative}}{\sum \text{Condition positive}}$	Specificity (SPC), Selectivity, True negative rate (TNR) = $\frac{\sum \text{True negative}}{\sum \text{Condition negative}}$	Negative likelihood ratio (LR-) = $\frac{\text{FNR}}{\text{TNR}}$	$F_1 \text{ score} = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$

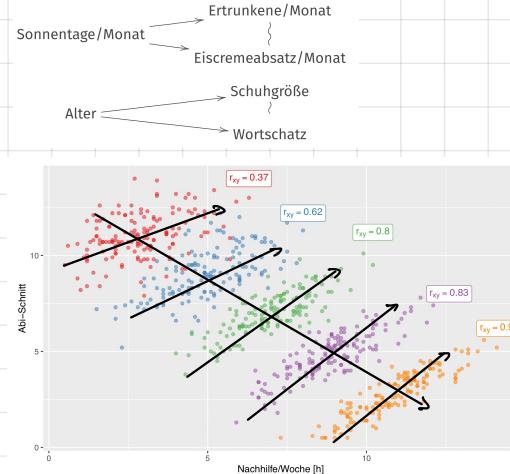
# Korrelation & Kausalität

$A \rightarrow B$ : "A ist Ursache von B"

$A \rightsquigarrow B$ : "A und B korrelieren (nicht stoch. unabhängig)"



## Confounding - Scheinkorrelation über Drittvariable

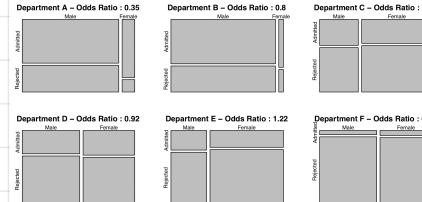


## Scheinkorrelation über Aggregation

### Aufnahmehilfe Uni Berkley

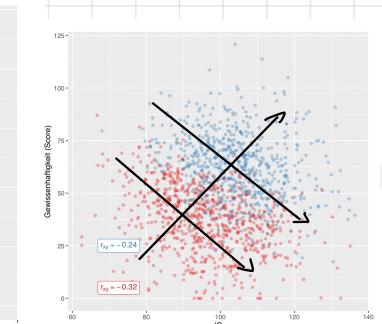
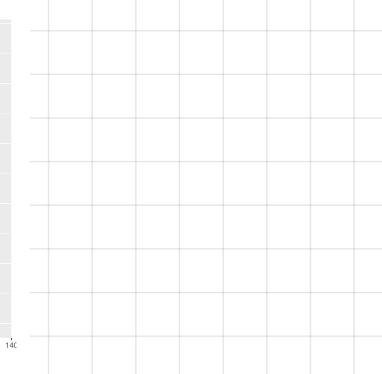
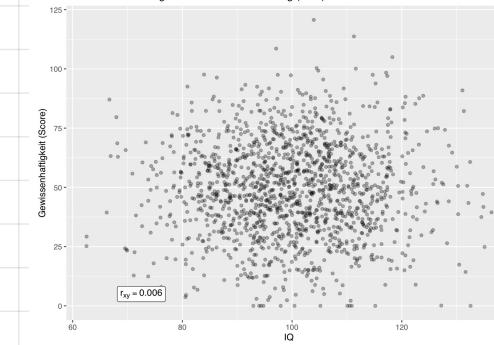
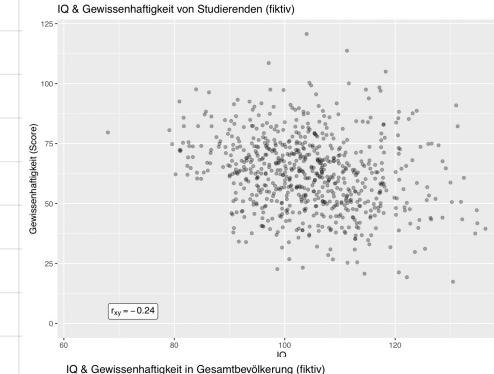


$$\gamma(\text{Admitted}, \text{Rejected} | \text{Male}, \text{Female}) = 1.83$$



Geschlecht ↘?  
Annahme  
Durch Mediator 'Fach' wird Assoziation zwischen Geschlecht und Annahme komplexer

## Conditioning on Collider - Scheinkorrelation durch Stichprobenselektion



Scheinkorrelation zwischen 'Fleiß' und 'Schlau' durch Conditioning auf 'Studieren'.  
Nur diejenigen, die eher schlau oder fleißig sind können studieren.  
Dadurch entsteht negative Korrelation zwischen Schlau und Fleiß in der Subpopulation der Studierenden.

Ob eine UE in der beobachteten Stichprobe ist, hängt von einer Variable ab, die von den untersuchten Variablen kausal abhängt. Selection-distortion-effect